CUDA ON ARM PLATFORM—利用共享存储单元优化应用

NVIDIA企业级开发者社区 何琨

利用共享存储单元优化应用

AGENDA

- 共享存储单元详解
- 共享内存的Bank conflict
- 利用共享存储单元进行矩阵相乘

多种CUDA存储单元

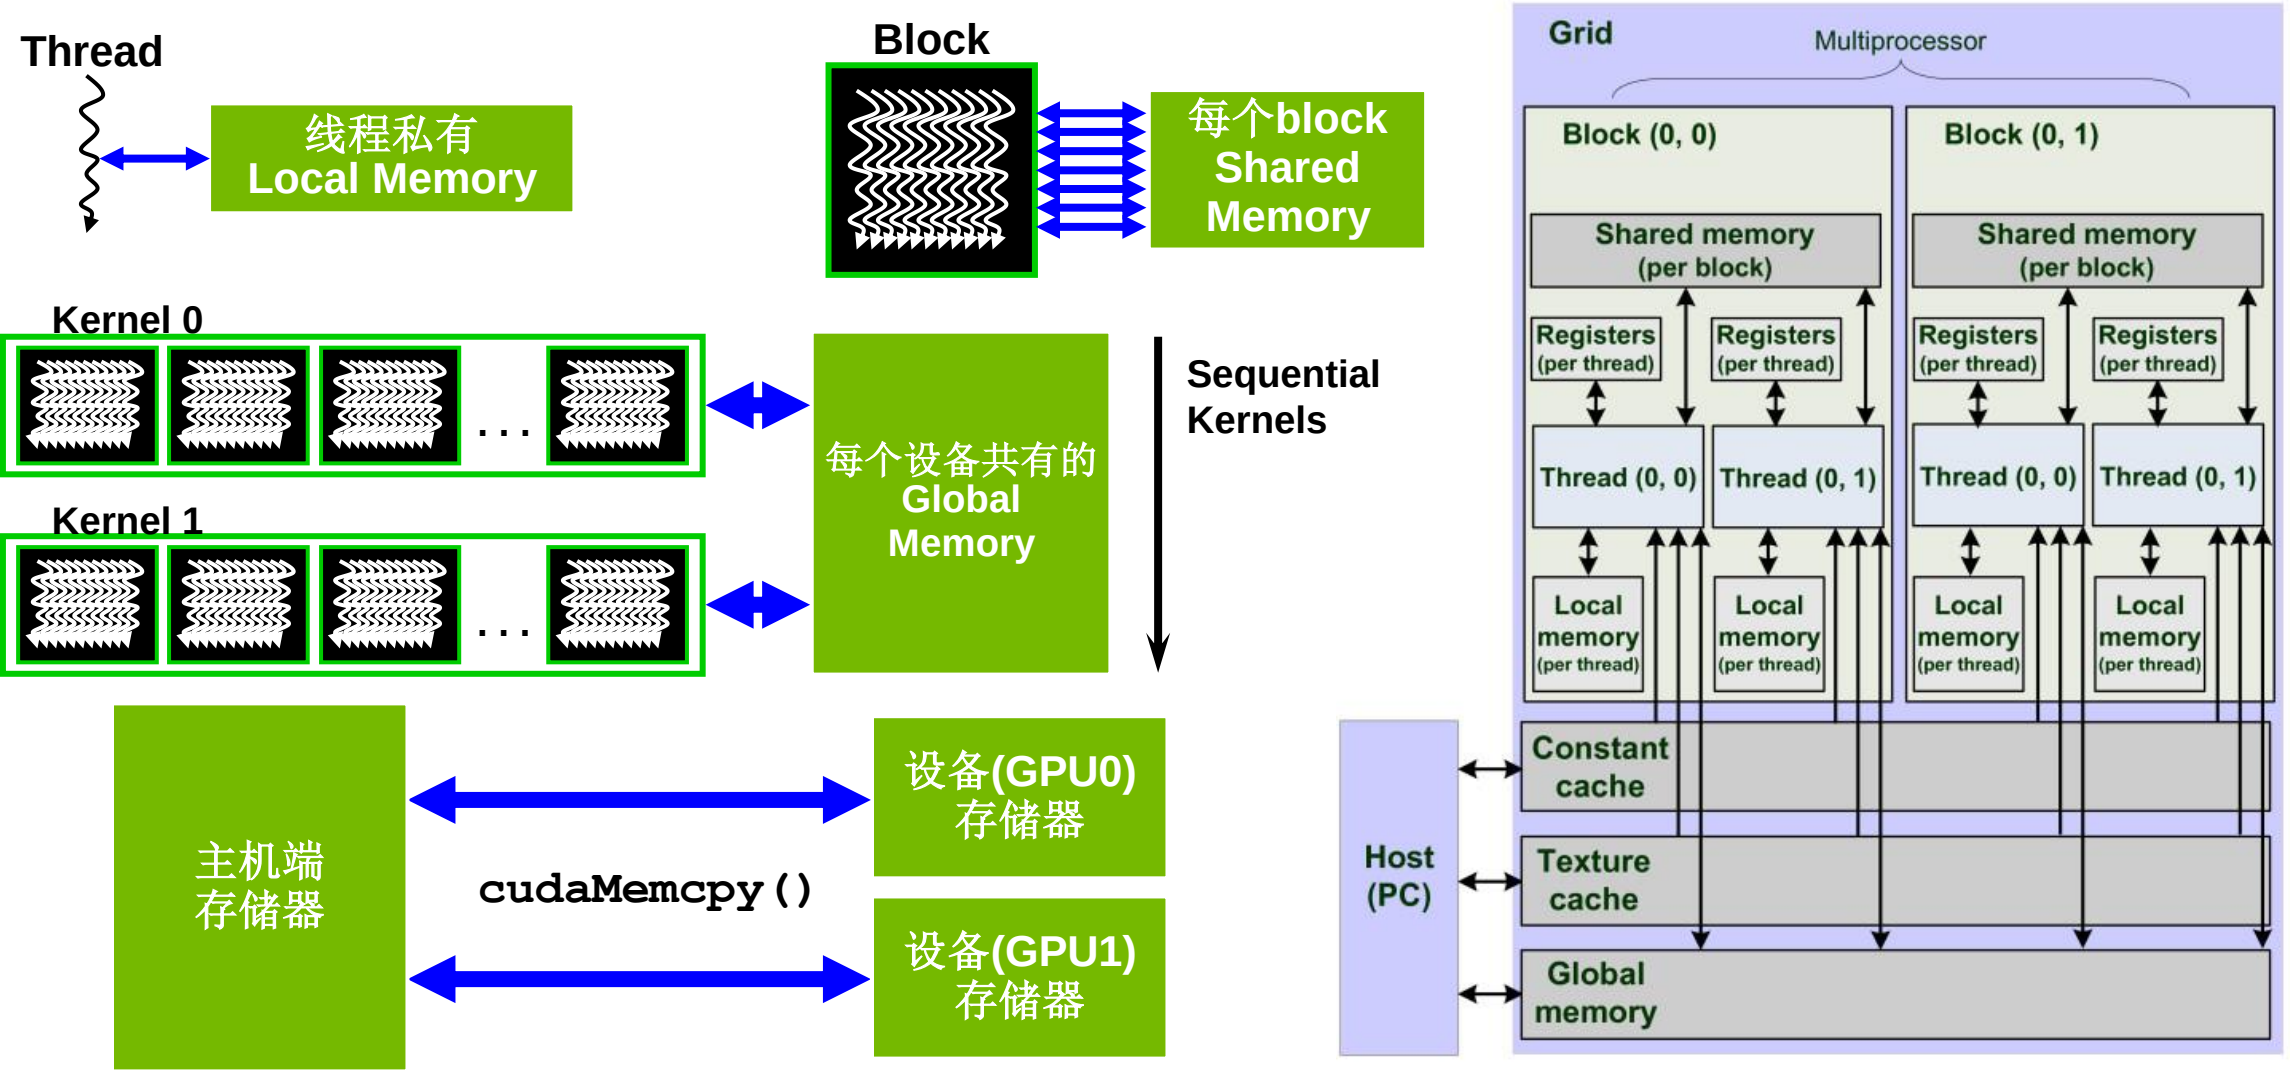
Thread
线程私有
Local Memory
Block
每个block
Shared
Memory
Kernel 0
Kernel 1
每个设备共有的
Global
Memory
Sequential
Kernels
主机端
存储器
cudaMemcpy()
设备(GPU0)
存储器
设备(GPU1)
存储器
Grid
Multiprocessor
Block (0, 0)
Block (0, 1)
Shared memory
(per block)
Registers
(per thread)
Thread (0, 0)
Thread (0, 1)
Local
memory
(per thread)
Host
(PC)
Constant
cache
Texture
cache
Global
memory

CUDA存储单元

Access speed

- Register file
- Shared Memory
- Constant Memory
- Texture Memory
- Local Memory and Global Memory

Shared Memory

Shared Memory：

The only two types of memory that actually reside on the GPU chip are register and shared memory.

所以，Shared Memory是目前最快的可以让多个线程沟通的地方。

那么，就有可能会出现同时有很多线程访问Shared Memory上的数据。

为了克服这个同时访问的瓶颈，Shared Memory被分成32个逻辑块（banks）

Successive sections of memory are assigned to successive banks

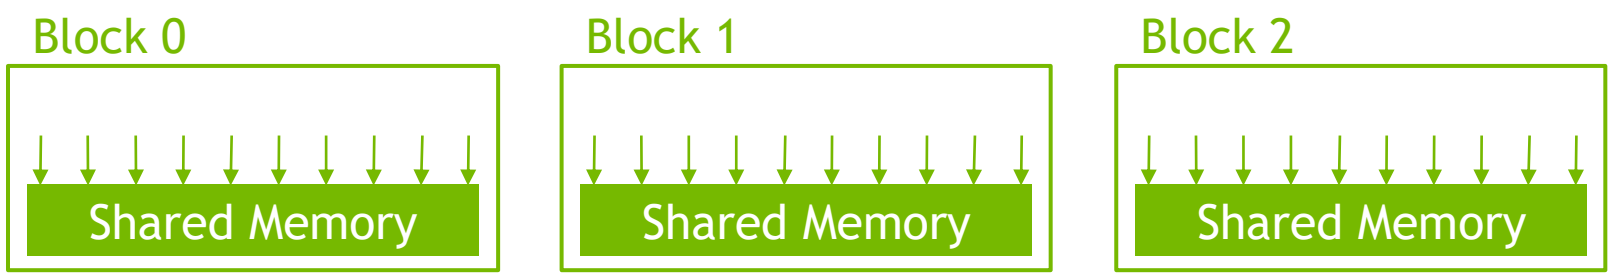

Shared Memory

Shared Memory：

静态分配: __shared__ int s[64];

动态分配: dynamicKernel<<<1, n, n*sizeof(int)>>>(d_d, n);

extern __shared__ int s[];

Shared Memory

Shared Memory：

- Shared Memory可以被设置成16KB，32KB，48KB…剩下的给L1缓存
- 带宽可以使32bit or 64 bit
- 很多线程访问存储器
- 因此, 存储器被划分为 banks
- 连续的 32-bit 访存 被分配到连续的 banks
- 每个 bank 每个周期可以响应一个地址
- 如果有多个bank的话可以同时响应更多地址申请

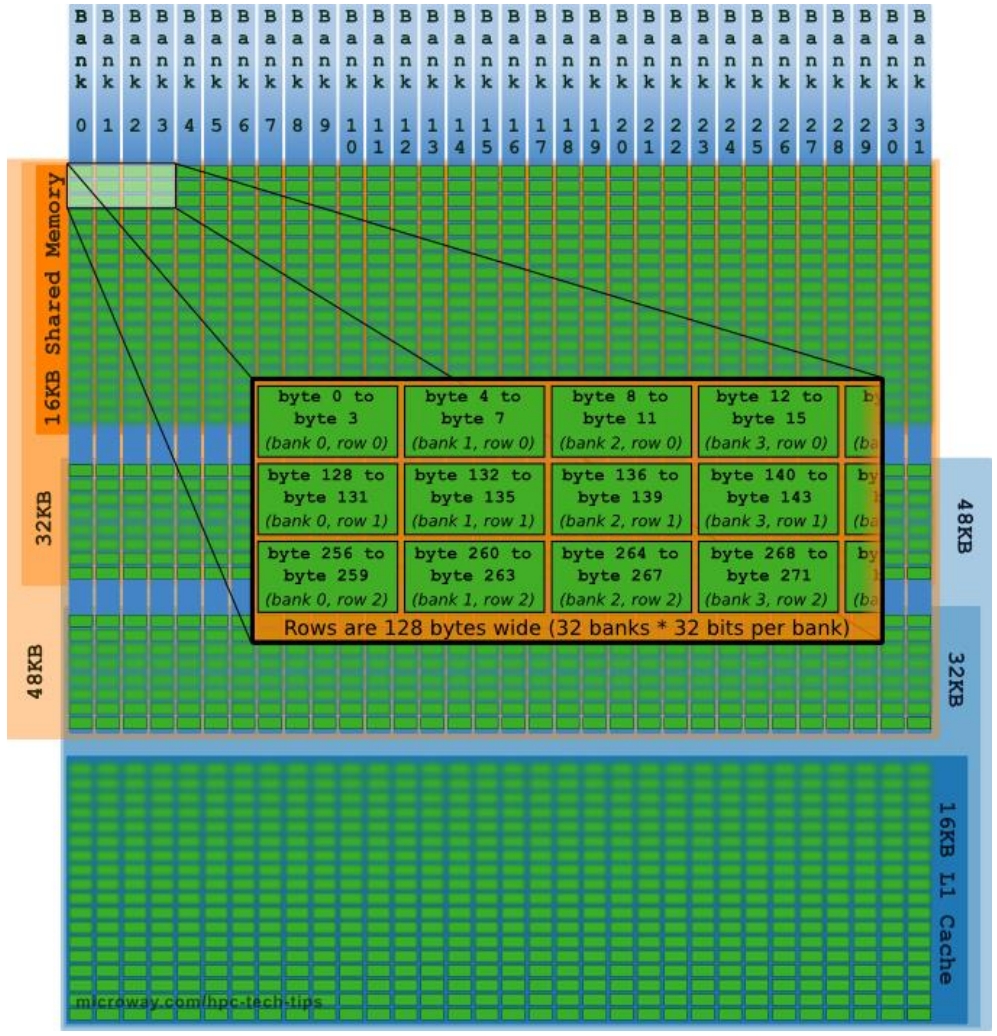

Shared memory

Bank conflict

1. 同常量内存一样，当一个 warp 中的所有线程访问同一地址的共享内存时，会触发一个广播（broadcast）机制到 warp 中所有线程，这是最高效的。
2. 如果同一个 half-warp/warp 中的线程访问同一个 bank 中的不同地址时将发生 bank conflict。
3. 每个 bank 除了能广播（broadcast）还可以多播（mutilcast）（计算能力 >= 2.0），也就是说，如果一个 warp 中的多个线程访问同一个 bank 的同一个地址时（其他线程也没有访问同一个bank 的不同地址）不会发生 bank conflict。
4. 即使同一个 warp 中的线程 随机的访问不同的 bank，只要没有访问同一个 bank 的不同地址就不会发生 bank conflict。

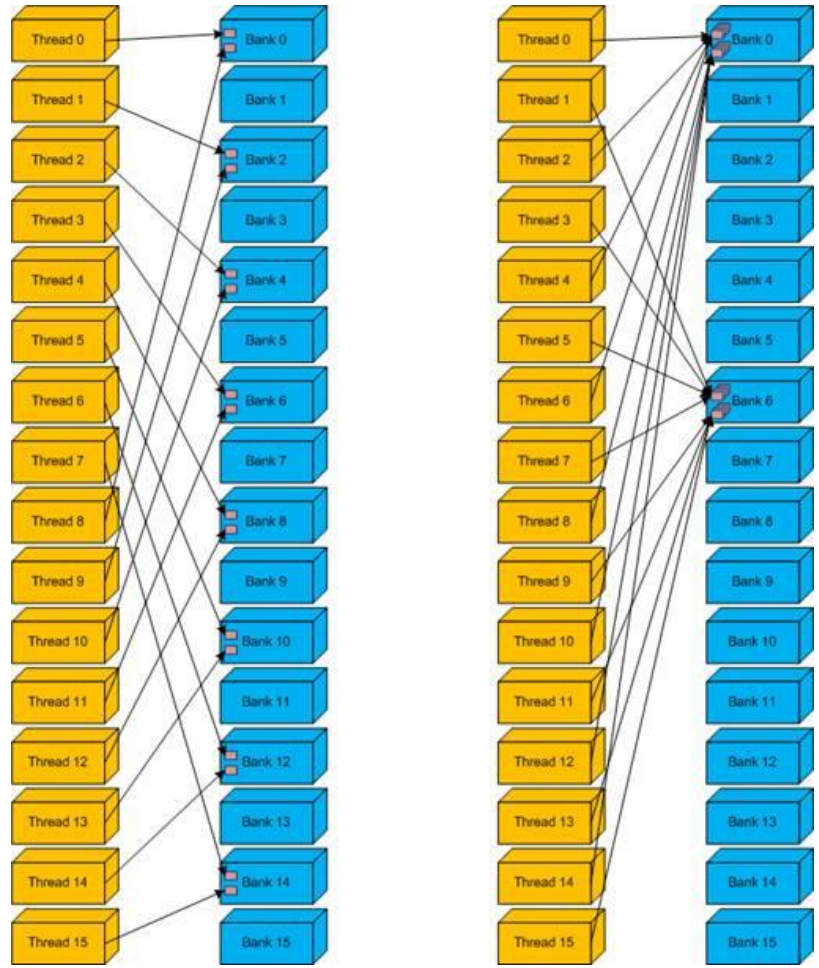

Shared memory

Shared memory 跟 registers 一样快， 如果没有bank冲突的话

快速情况:

- **warp 内所有线程访问 不同 banks, 没有冲突**
- **warp 内所有线程读取同一地址,没有冲突(广播)**

慢速情况:

- **Bank Conflict: warp 内多个线程访问同一个bank**
- **访存必须串行化**
- **代价 = 多个线程同时访问同一个bank 的线程数最大值**

Shared memory

如何避免 Bank conflict

Shared memory

如何避免 Bank conflict

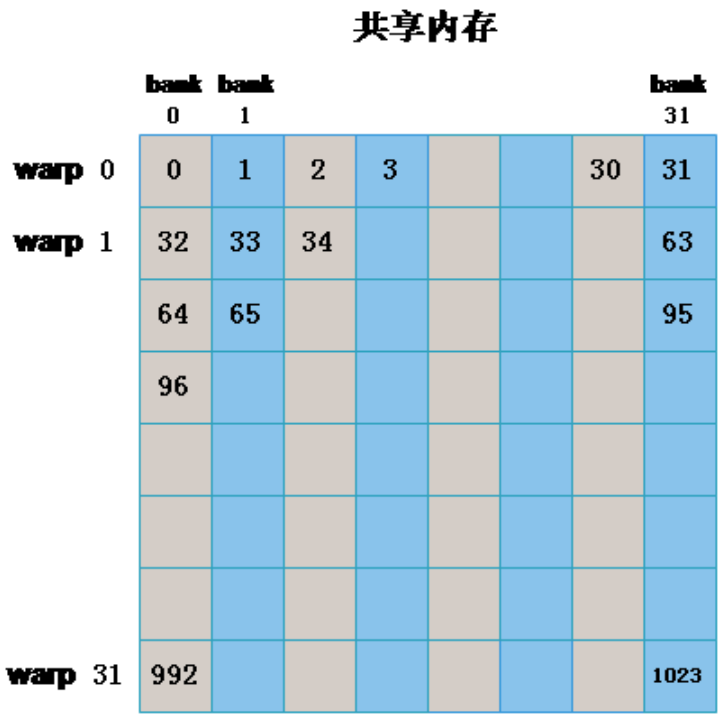

此时是没有 bank conflict

```
int x_id = blockDim.x * blockIdx.x + threadIdx.x; //列坐标
int y_id = blockDim.y * blockIdx.y + threadIdx.y; //行坐标
int index = y_id * col + x_id;

__shared__ float sData[BLOCKSIZE][BLOCKSIZE];

if (x_id < col && y_id < row)
{
    sData[threadIdx.y][threadIdx.x] = matrix[index];
    __syncthreads();
    matrixTest[index] = sData[threadIdx.y][threadIdx.x];
}
```

Shared memory

如何避免 Bank conflict

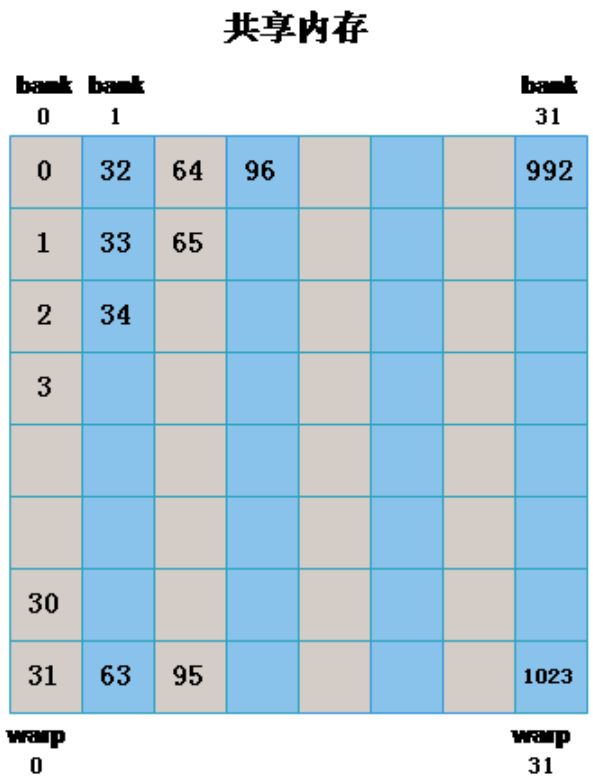

此时是有 bank conflict

```
int x_id = blockDim.x * blockIdx.x + threadIdx.x; //列坐标
int y_id = blockDim.y * blockIdx.y + threadIdx.y; //行坐标
int index = y_id * col + x_id;

__shared__ float sData[BLOCKSIZE][BLOCKSIZE];

if (x_id < col && y_id < row)
{
    sData[threadIdx.x][threadIdx.y] = matrix[index];
    __syncthreads();
    matrixTest[index] = sData[threadIdx.x][threadIdx.y];
}
```

Shared memory

如何避免 Bank conflict

Memory Padding

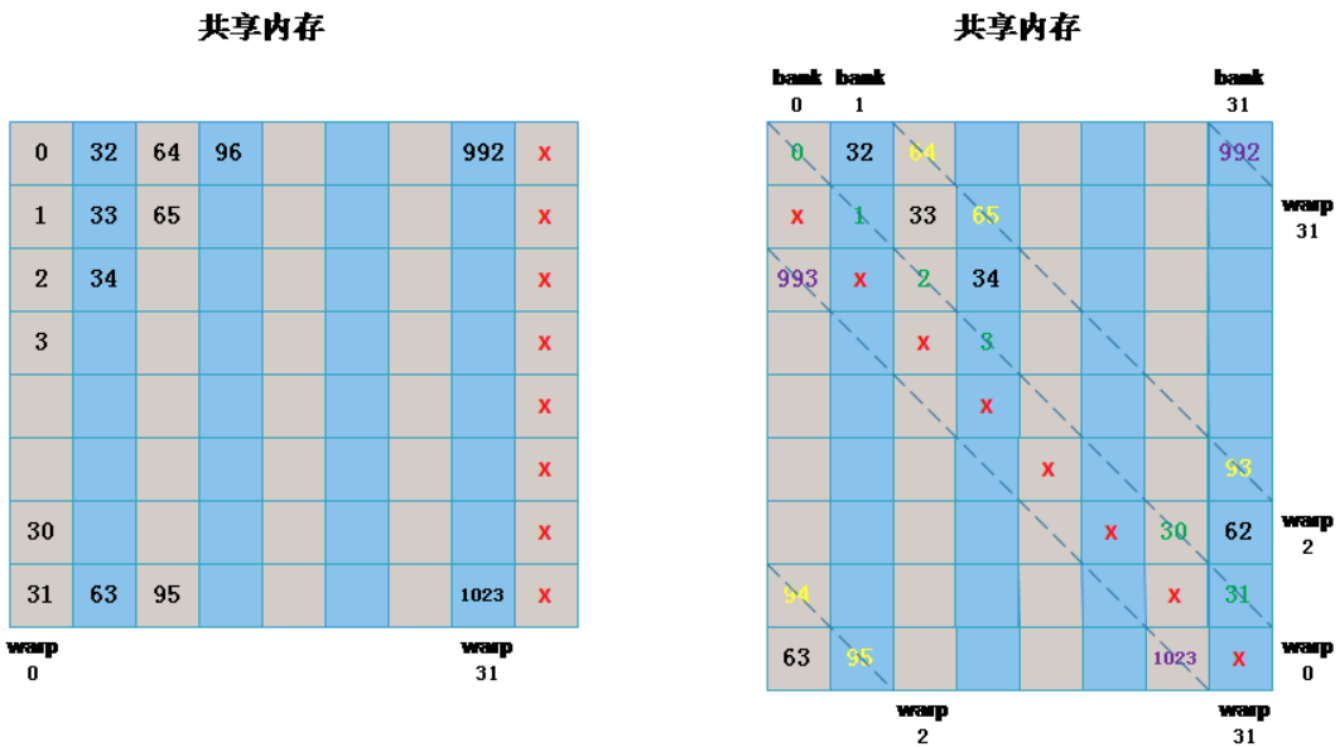

Shared memory

如何避免 Bank conflict

Memory Padding

```
int x_id = blockDim.x * blockIdx.x + threadIdx.x; //列坐标
int y_id = blockDim.y * blockIdx.y + threadIdx.y; //行坐标
int index = y_id * col + x_id;

__shared__ float sData[BLOCKSIZE][BLOCKSIZE+1];

if (x_id < col && y_id < row)
{
    sData[threadIdx.x][threadIdx.y] = matrix[index];
    __syncthreads();
    matrixTest[index] = sData[threadIdx.x][threadIdx.y];
}
```

- 每个输入元素被Width 个线程读取
- 使用 shared memory 来减少 global memory 带宽需求

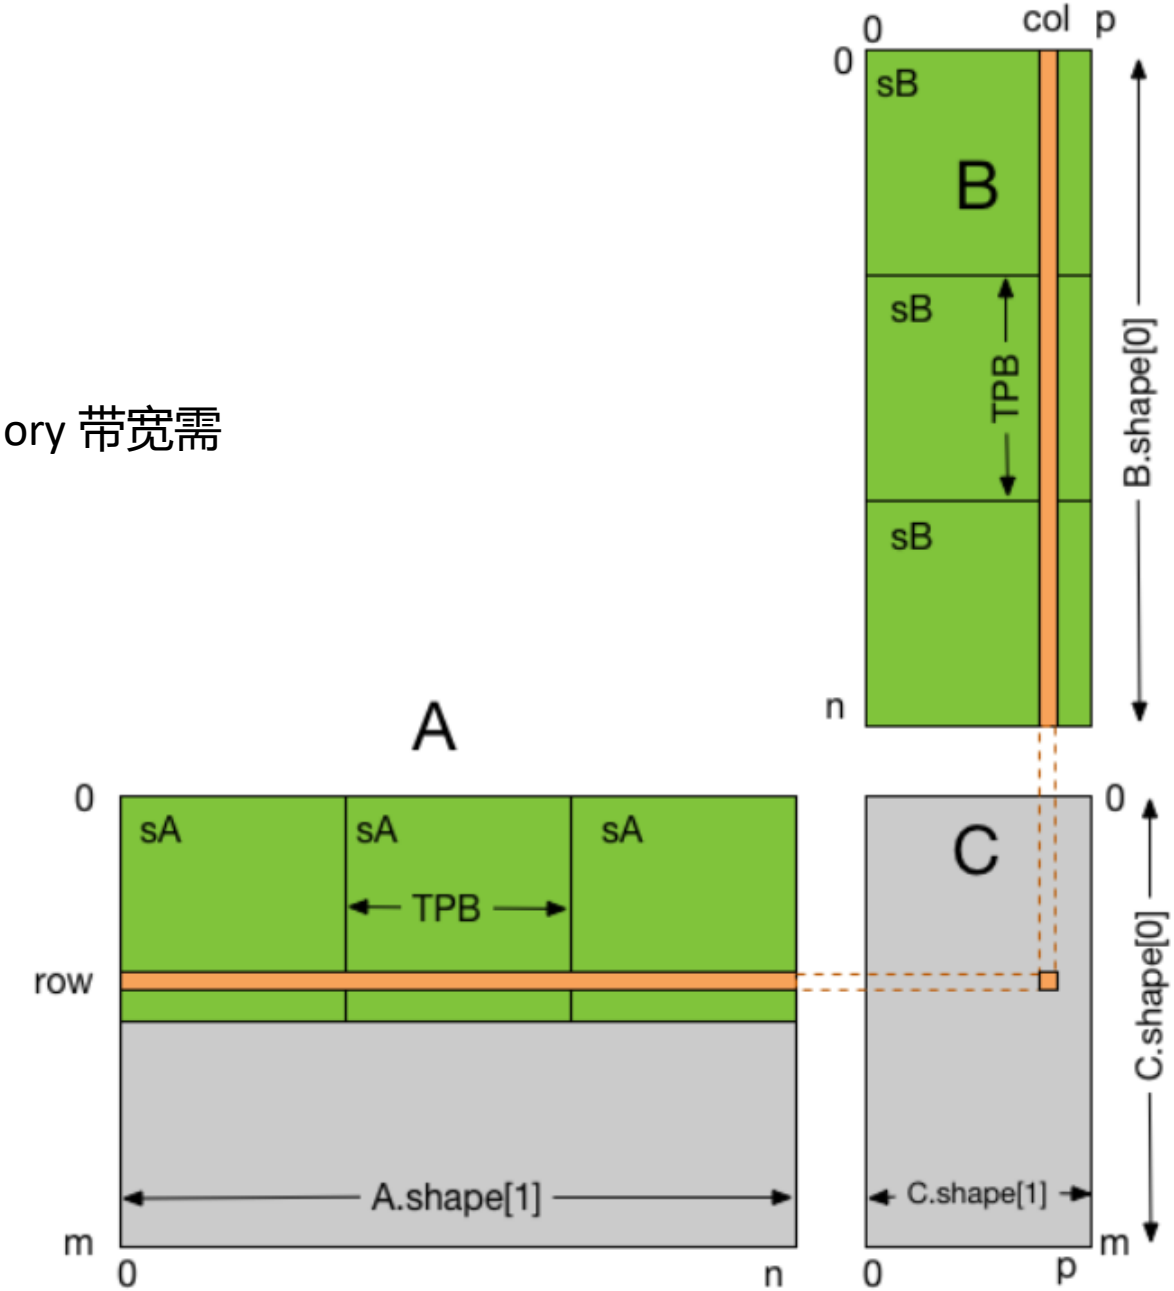

CUDA 矩阵乘示例：

假设：M[16][16] * N[16][16] = P[16][16]

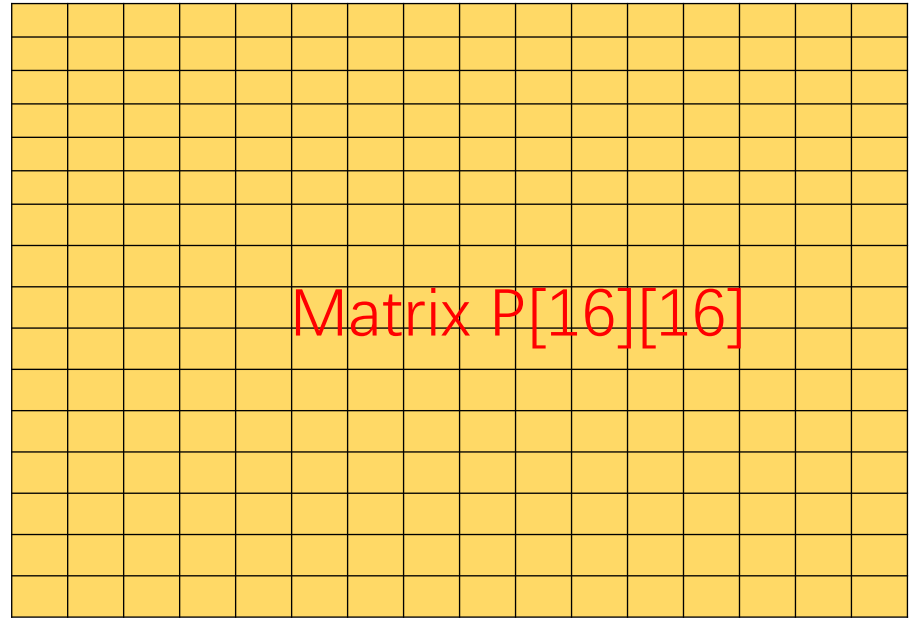

CUDA 矩阵乘示例：
我们要求一个结果矩阵P的维度是16*16
而P矩阵在实际存储单元中，是保存在连续地址的一维存储空间中，如下图所示

我们申请线程，设置：
gridDim(2,2)　　blockDim(8,8)
保证每一个线程，负责求出P矩阵中一个位置的值
如下图所示，每个小格子代表一个thread，同一个颜色覆盖的区域代表一个Block。**坐标示意：(threadIdx.y, thread.x)**

Matrix P

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31
32	33	34	35	36	37	38	39	40	41	42	43	44	45	46	47
48	49	50	51	52	53	54	55	56	57	58	59	60	61	62	63
64	65	66	67	68	69	70	71	72	73	74	75	76	77	78	79
80	81	82	83	84	85	86	87	88	89	90	91	92	93	94	95
96	97	98	99	100	101	102	103	104	105	106	107	108	109	110	111
112	113	114	115	116	117	118	119	120	121	122	123	124	125	126	127
128	129	130	131	132	133	134	135	136	137	138	139	140	141	142	143
144	145	146	147	148	149	150	151	152	153	154	155	156	157	158	159
160	161	162	163	164	165	166	167	168	169	170	171	172	173	174	175
176	177	178	179	180	181	182	183	184	185	186	187	188	189	190	191
192	193	194	195	196	197	198	199	200	201	202	203	204	205	206	207
208	209	210	211	212	213	214	215	216	217	218	219	220	221	222	223
224	225	226	227	228	229	230	231	232	233	234	235	236	237	238	239
240	241	242	243	244	245	246	247	248	249	250	251	252	253	254	255

Grid

(0,0)	(0,1)	(0,2)	(0,3)	(0,4)	(0,5)	(0,6)	(0,7)	(0,0)	(0,1)	(0,2)	(0,3)	(0,4)	(0,5)	(0,6)	(0,7)
(1,0)	(1,1)	(1,2)	(1,3)	(1,4)	(1,5)	(1,6)	(1,7)	(1,0)	(1,1)	(1,2)	(1,3)	(1,4)	(1,5)	(1,6)	(1,7)
(2,0)	(2,1)	(2,2)	(2,3)	(2,4)	(2,5)	(2,6)	(2,7)	(2,0)	(2,1)	(2,2)	(2,3)	(2,4)	(2,5)	(2,6)	(2,7)
(3,0)	(3,1)	(3,2)	(3,3)	(3,4)	(3,5)	(3,6)	(3,7)	(3,0)	(3,1)	(3,2)	(3,3)	(3,4)	(3,5)	(3,6)	(3,7)
(4,0)	(4,1)	(4,2)	(4,3)	(4,4)	(4,5)	(4,6)	(4,7)	(4,0)	(4,1)	(4,2)	(4,3)	(4,4)	(4,5)	(4,6)	(4,7)
(5,0)	(5,1)	(5,2)	(5,3)	(5,4)	(5,5)	(5,6)	(5,7)	(5,0)	(5,1)	(5,2)	(5,3)	(5,4)	(5,5)	(5,6)	(5,7)
(6,0)	(6,1)	(6,2)	(6,3)	(6,4)	(6,5)	(6,6)	(6,7)	(6,0)	(6,1)	(6,2)	(6,3)	(6,4)	(6,5)	(6,6)	(6,7)
(7,0)	(7,1)	(7,2)	(7,3)	(7,4)	(7,5)	(7,6)	(7,7)	(7,0)	(7,1)	(7,2)	(7,3)	(7,4)	(7,5)	(7,6)	(7,7)
(0,0)	(0,1)	(0,2)	(0,3)	(0,4)	(0,5)	(0,6)	(0,7)	(0,0)	(0,1)	(0,2)	(0,3)	(0,4)	(0,5)	(0,6)	(0,7)
(1,0)	(1,1)	(1,2)	(1,3)	(1,4)	(1,5)	(1,6)	(1,7)	(1,0)	(1,1)	(1,2)	(1,3)	(1,4)	(1,5)	(1,6)	(1,7)
(2,0)	(2,1)	(2,2)	(2,3)	(2,4)	(2,5)	(2,6)	(2,7)	(2,0)	(2,1)	(2,2)	(2,3)	(2,4)	(2,5)	(2,6)	(2,7)
(3,0)	(3,1)	(3,2)	(3,3)	(3,4)	(3,5)	(3,6)	(3,7)	(3,0)	(3,1)	(3,2)	(3,3)	(3,4)	(3,5)	(3,6)	(3,7)
(4,0)	(4,1)	(4,2)	(4,3)	(4,4)	(4,5)	(4,6)	(4,7)	(4,0)	(4,1)	(4,2)	(4,3)	(4,4)	(4,5)	(4,6)	(4,7)
(5,0)	(5,1)	(5,2)	(5,3)	(5,4)	(5,5)	(5,6)	(5,7)	(5,0)	(5,1)	(5,2)	(5,3)	(5,4)	(5,5)	(5,6)	(5,7)
(6,0)	(6,1)	(6,2)	(6,3)	(6,4)	(6,5)	(6,6)	(6,7)	(6,0)	(6,1)	(6,2)	(6,3)	(6,4)	(6,5)	(6,6)	(6,7)
(7,0)	(7,1)	(7,2)	(7,3)	(7,4)	(7,5)	(7,6)	(7,7)	(7,0)	(7,1)	(7,2)	(7,3)	(7,4)	(7,5)	(7,6)	(7,7)

CUDA 矩阵乘示例：
那么，下面右图中紫色区域覆盖的block就会负责求出P矩阵中相对应的位置的值（下面左图中紫色区域覆盖的位置）

Matrix P

0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31
32	33	34	35	36	37	38	39	40	41	42	43	44	45	46	47
48	49	50	51	52	53	54	55	56	57	58	59	60	61	62	63
64	65	66	67	68	69	70	71	72	73	74	75	76	77	78	79
80	81	82	83	84	85	86	87	88	89	90	91	92	93	94	95
96	97	98	99	100	101	102	103	104	105	106	107	108	109	110	111
112	113	114	115	116	117	118	119	120	121	122	123	124	125	126	127
128	129	130	131	132	133	134	135	136	137	138	139	140	141	142	143
144	145	146	147	148	149	150	151	152	153	154	155	156	157	158	159
160	161	162	163	164	165	166	167	168	169	170	171	172	173	174	175
176	177	178	179	180	181	182	183	184	185	186	187	188	189	190	191
192	193	194	195	196	197	198	199	200	201	202	203	204	205	206	207
208	209	210	211	212	213	214	215	216	217	218	219	220	221	222	223
224	225	226	227	228	229	230	231	232	233	234	235	236	237	238	239
240	241	242	243	244	245	246	247	248	249	250	251	252	253	254	255

Grid

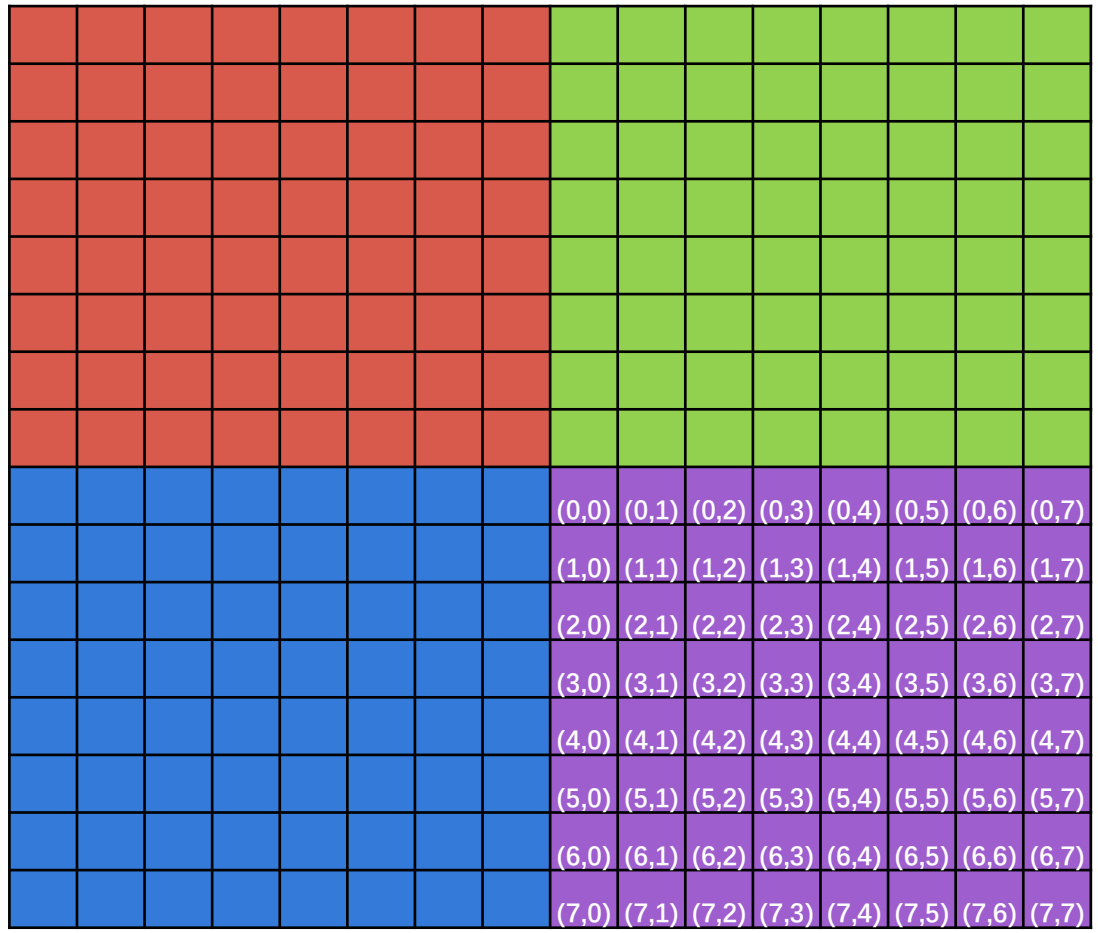

CUDA 矩阵乘示例：
那么，下图Grid中紫色区域的block，将会读取M矩阵中紫色区域的行 和 N矩阵中紫色区域的列。

因为，M中的行 和 N中的列将会被多次读取，所以我们就将M中的紫色区域覆盖的行和N中紫色区域覆盖的列存入Shared Memory中来提高访存效率。

因为空间优先，所以要滑动小块，重复利用shared memory的空间

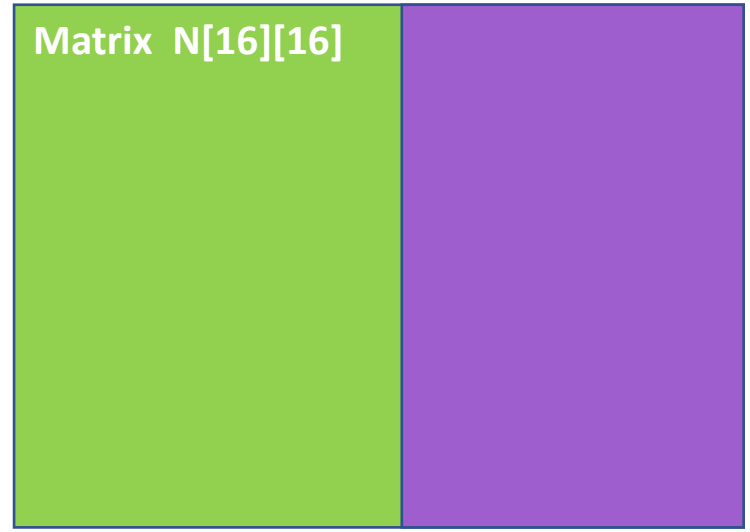

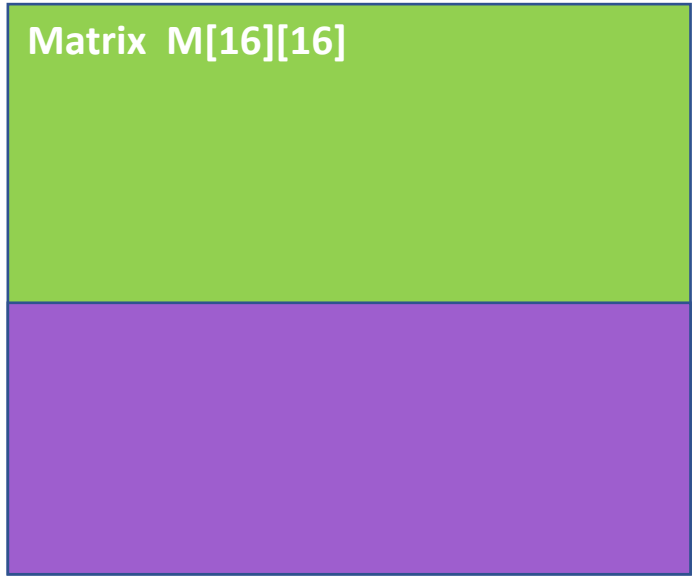

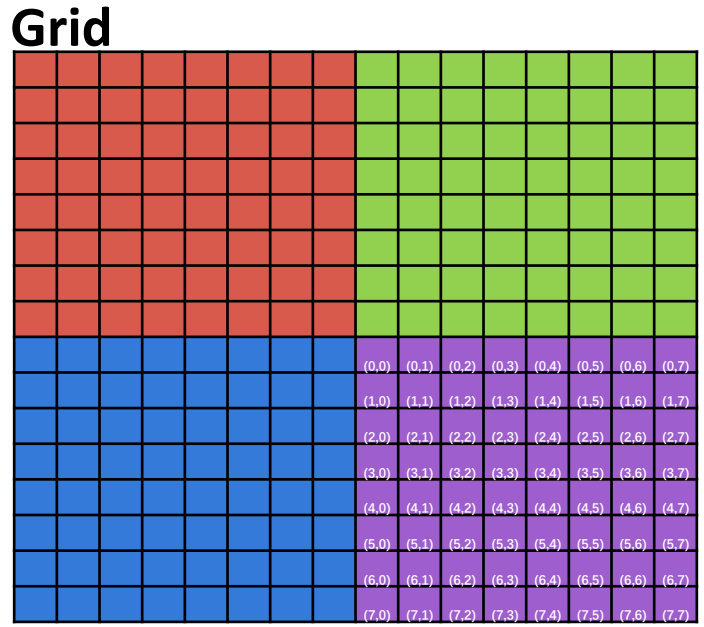

CUDA 矩阵乘示例：
首先我们会申请两块shared memory：
__shared__ int tile_m[BLOCK_SIZE][BLOCK_SIZE];
__shared__ int tile_n[BLOCK_SIZE][BLOCK_SIZE];

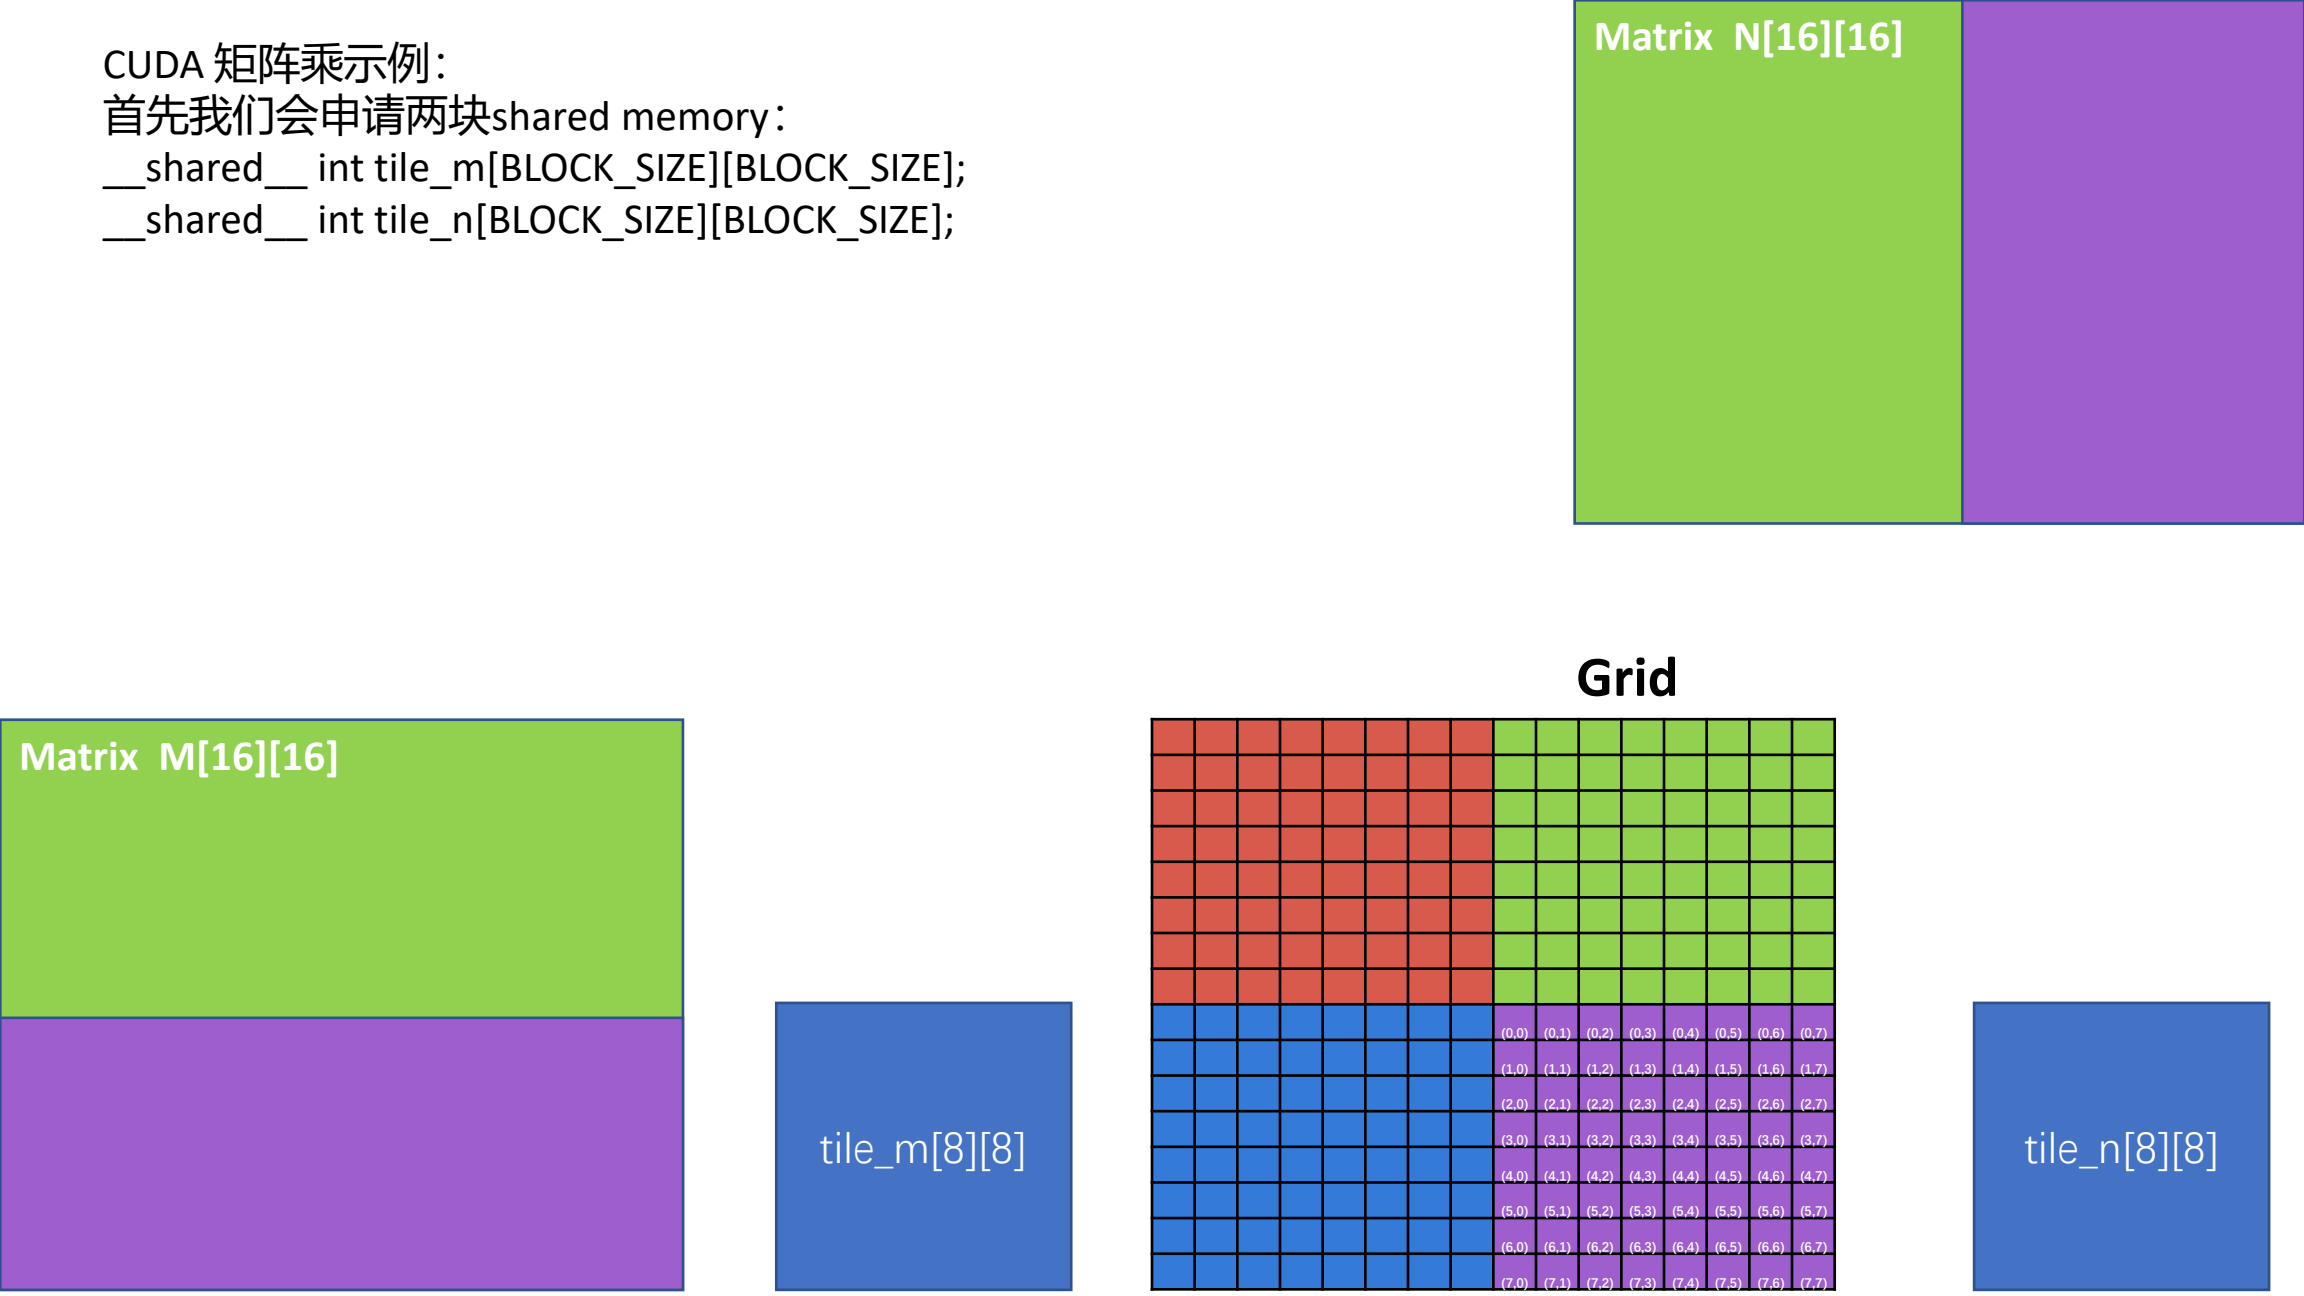

CUDA 矩阵乘示例：

接下来，Grid中紫色区域覆盖的block中的线程，从M矩阵中读取数值，并放到tile_m中：此时sub = 0 且 sub < 2(gridDim.x)

```
idx = row * n + sub * BLOCK_SIZE + threadIdx.x;
if(row<n && (sub * BLOCK_SIZE + threadIdx.x)<n )
{
    tile_m[threadIdx.y][threadIdx.x] = d_m[idx];
}
else{
    tile_m[threadIdx.y][threadIdx.x] = 0;
}
```

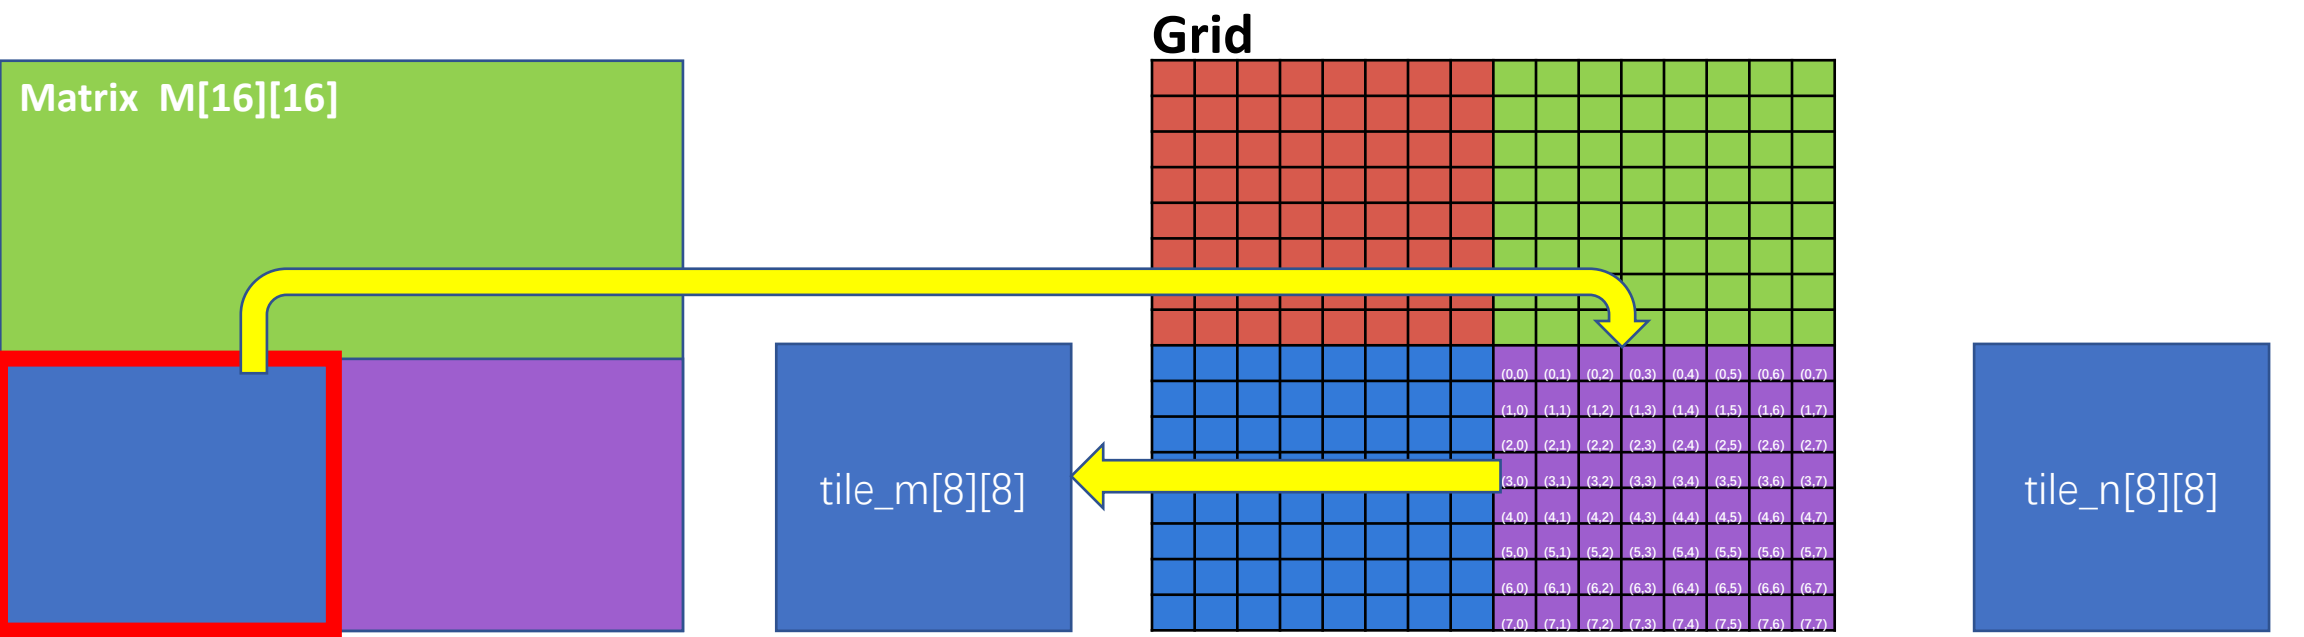

CUDA 矩阵乘示例：

接下来，Grid中紫色区域覆盖的block中的线程，从M矩阵中读取数值，并放到tile_m中：此时sub = 0且 sub < 2(gridDim.x)

```
idx = row * n + sub * BLOCK_SIZE + threadIdx.x;
if(row<n && (sub * BLOCK_SIZE + threadIdx.x)<n )
{
    tile_m[threadIdx.y][threadIdx.x] = d_m[idx];
}
else{
    tile_m[threadIdx.y][threadIdx.x] = 0;
}
```

其中，最难理解的是这个idx：

idx = row * n + sub * BLOCK_SIZE + threadIdx.x;

我们以thread(3,4)为例，该线程的索引值：

threadIdx.x = 4
threadIdx.y = 3
blockIdx.x = 1
blockIdx.y = 1

此时，我们sub的迭代步骤为0，即sub=0

row * n:
该线程所在行之前所有行包含的数据

row * n

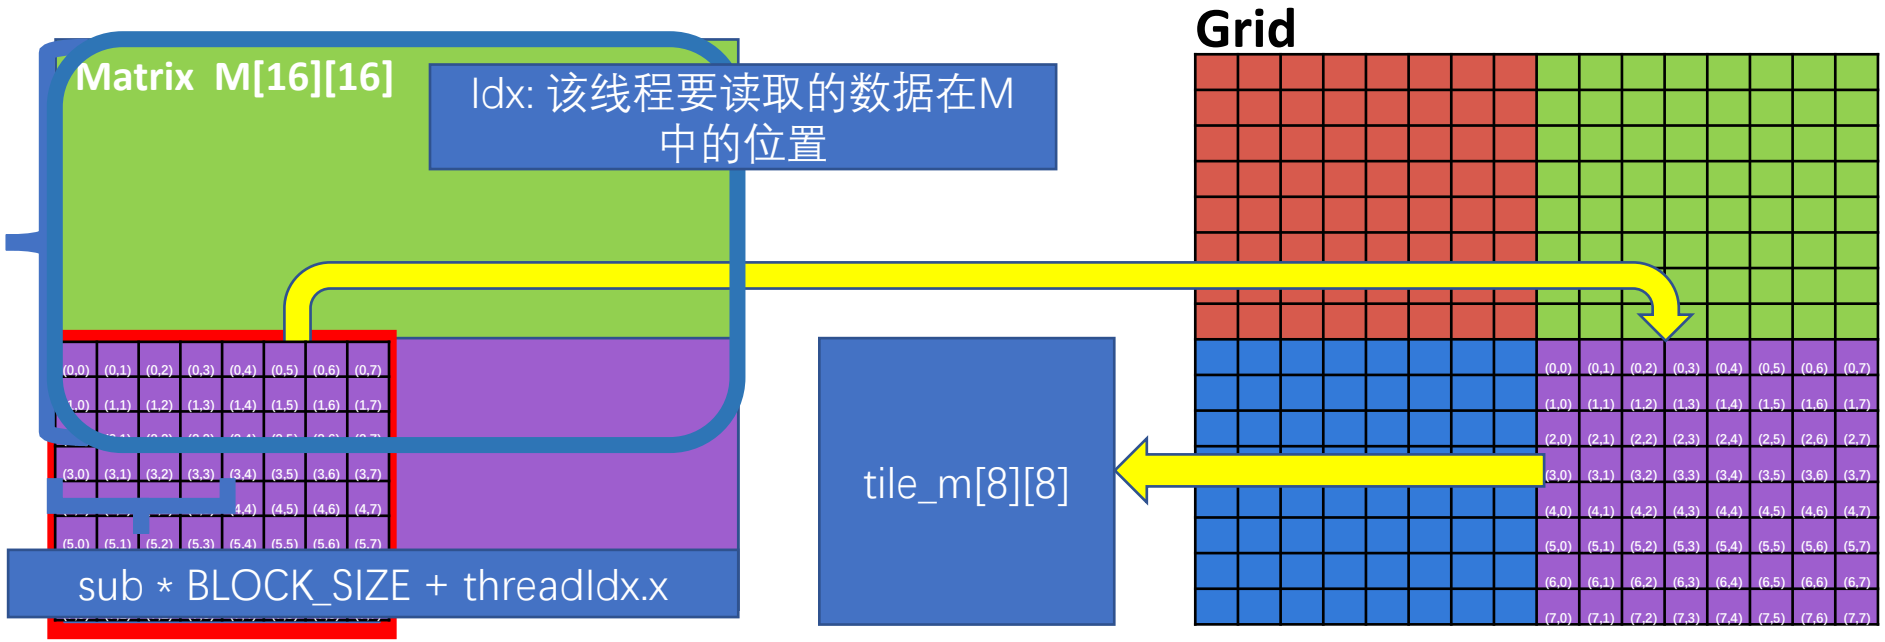

sub * BLOCK_SIZE + threadIdx.x:
该线程要读的数据在它所在的行中的位置

CUDA 矩阵乘示例：

接下来，Grid中紫色区域覆盖的block中的线程，从N矩阵中读取数值，并放到tile_n中：此时sub = 0且 sub < 2(gridDim.x)

```
idx = (sub * BLOCK_SIZE + threadIdx.y) * n + col;
if(col<n && (sub * BLOCK_SIZE + threadIdx.y)<n )
{
    tile_n[threadIdx.y][threadIdx.x] = d_n[idx];
}
else{
    tile_n[threadIdx.y][threadIdx.x] = 0;
}
```

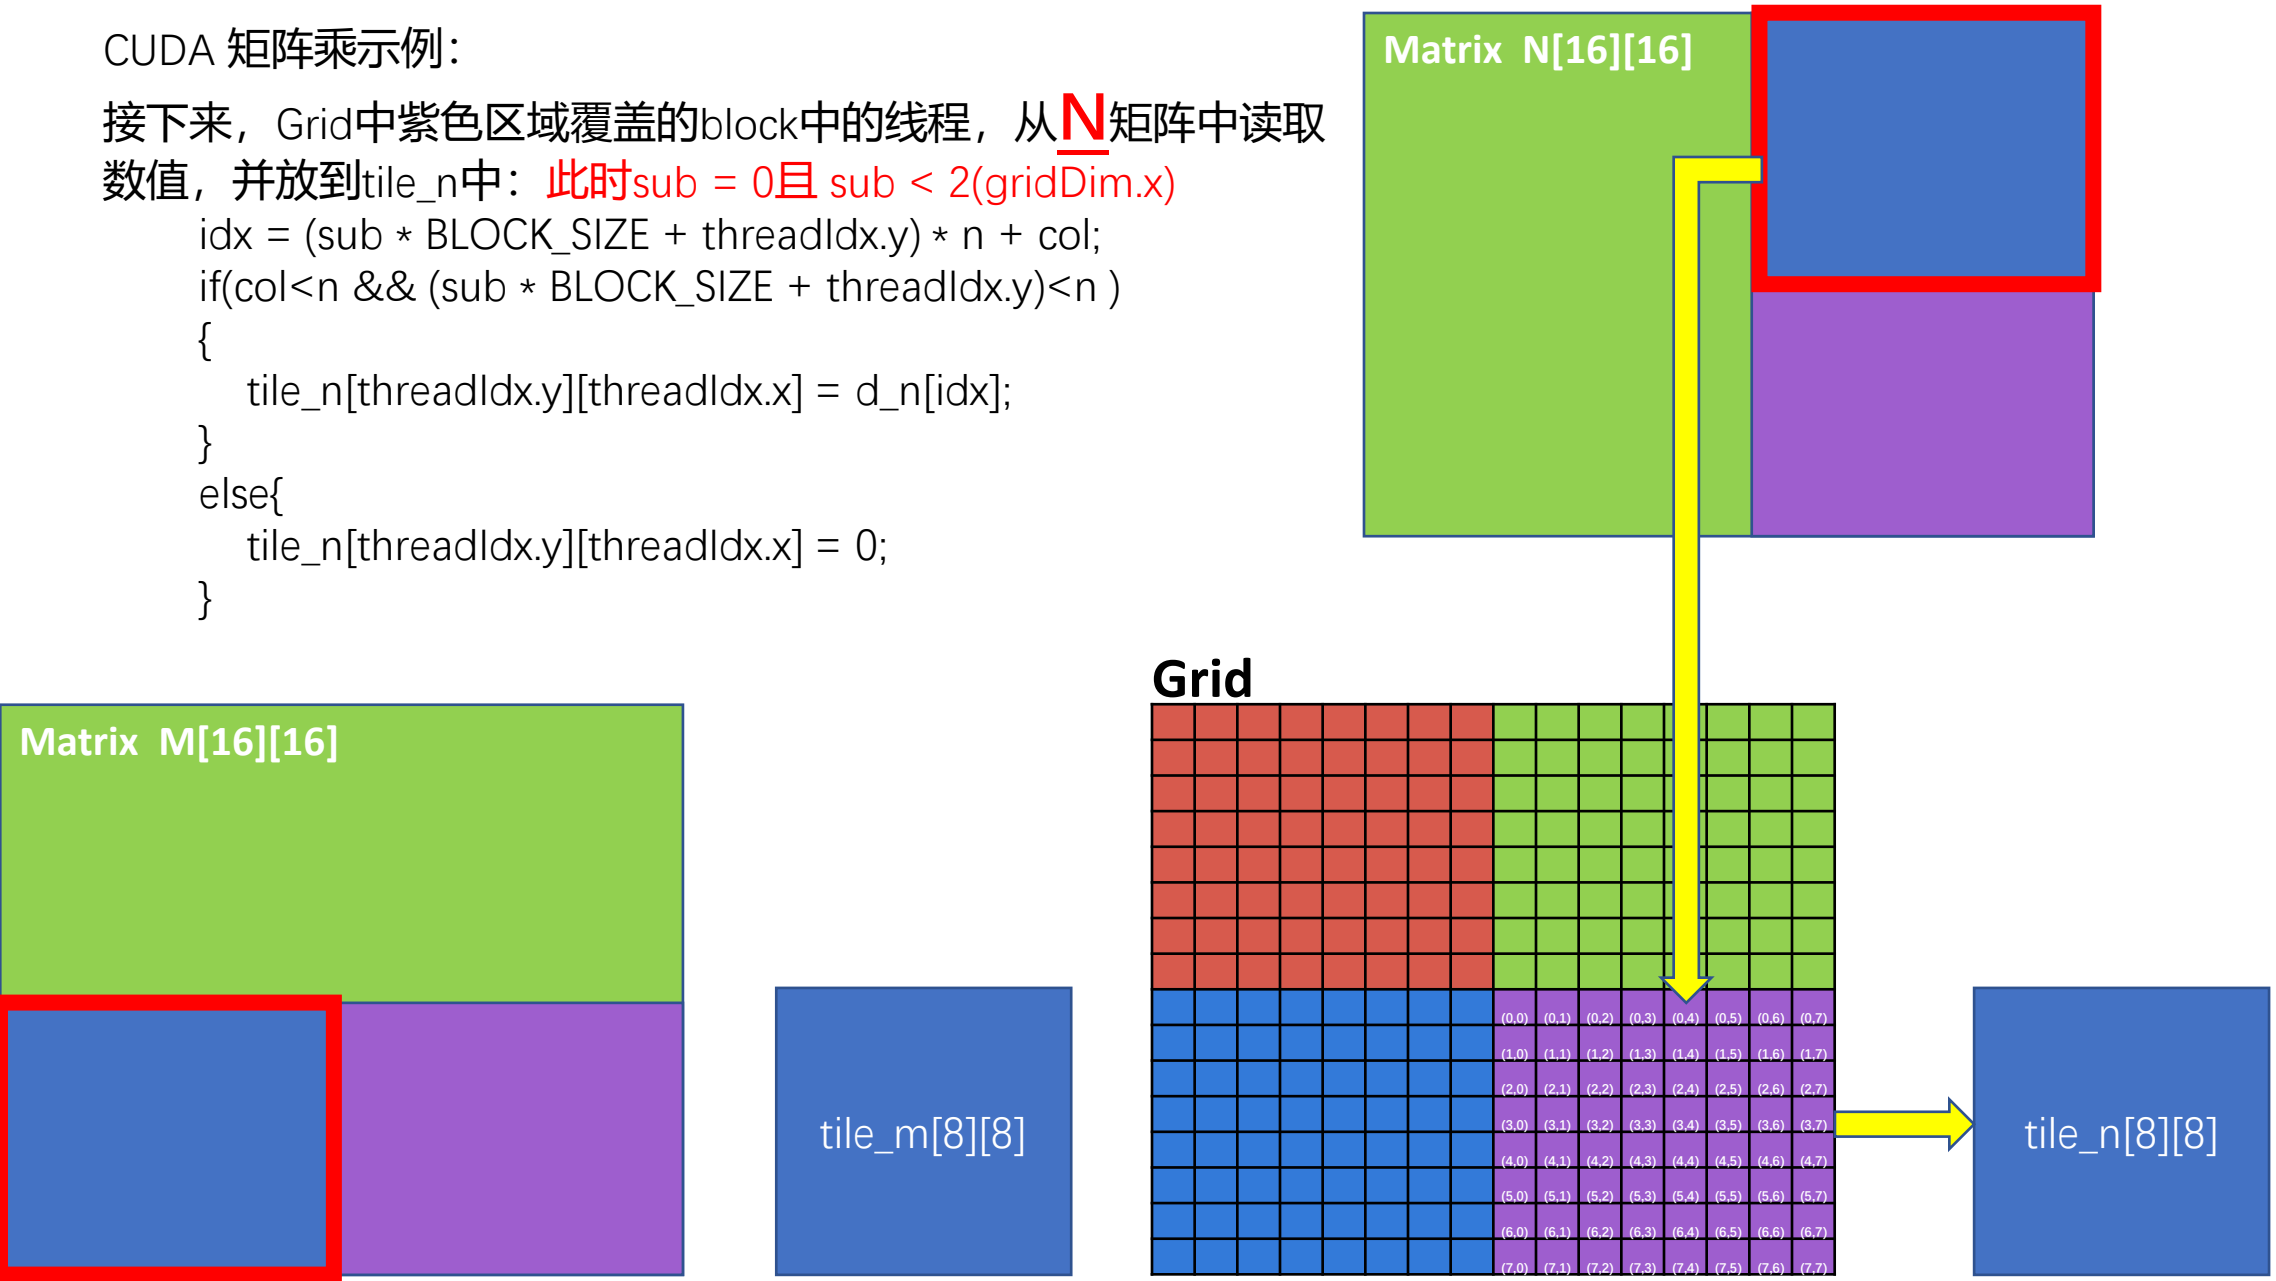

CUDA 矩阵乘示例：

接下来，Grid中紫色区域覆盖的block中的线程，从N矩阵中读取数值，并放到tile_n中：此时sub = 0且 sub < 2(gridDim.x)

```
idx = (sub * BLOCK_SIZE + threadIdx.y) * n + col;
if(col<n && (sub * BLOCK_SIZE + threadIdx.y)<n )
{
    tile_n[threadIdx.y][threadIdx.x] = d_n[idx];
}
else{
    tile_n[threadIdx.y][threadIdx.x] = 0;
}
```

(sub * BLOCK_SIZE + threadIdx.y) * n:
表示该线程所在行之前所有的数据

col :表示该线程要读取的数据在所在行的位置

Idx: 该线程要读取的数据在N中的位置

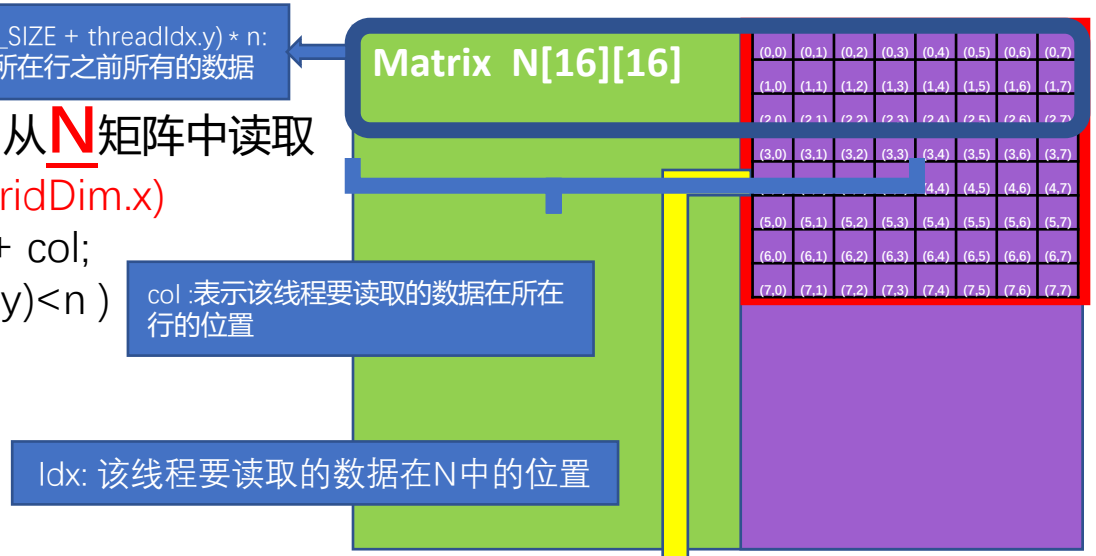

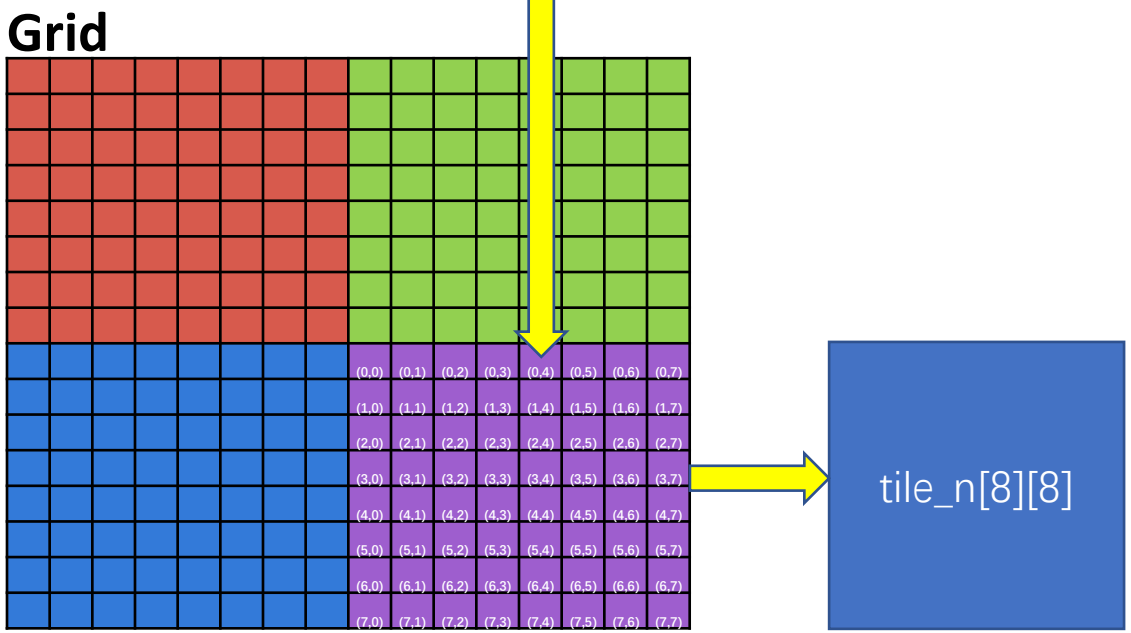

其中，最难理解的还是这个idx：

```
idx = (sub * BLOCK_SIZE + threadIdx.y) * n + col;
```

我们还是以thread(3,4)为例，该线程的索引值：

```
threadIdx.x = 4
threadIdx.y = 3
blockIdx.x  = 1
blockIdx.y  = 1
```

此时，我们sub的迭代步骤为0，即sub=0

CUDA 矩阵乘示例：

同步完所有的线程之后，我们紫色区域覆盖的线程块中的线程对已经读取到的两个tile中的矩阵进行相乘：

此时sub = 0且 sub < 2(gridDim.x)

```
__syncthreads();
for (int k = 0; k < BLOCK_SIZE; ++k)
{
    tmp += tile_m[threadIdx.y][k] * tile_n[k][threadIdx.x];
}
__syncthreads();
```

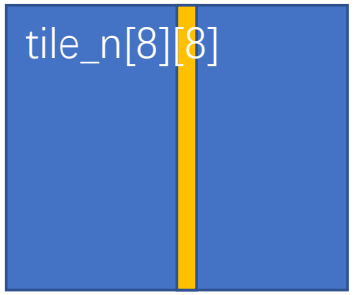

此时还以thread(3,4)为例：

它会将tile_m中index为3的行与tile_n中index为4的列相乘

将sub迭代步骤为0时计算得到的记过存储在tmp中

然后同步一下，让所有的线程都完成操作。以便在下一步中向shared memory中写入新的数值时不会影响这一步的计算。

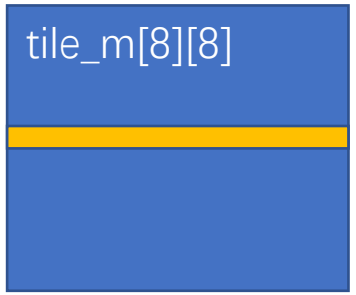

CUDA 矩阵乘示例：

接下来，Grid中紫色区域覆盖的block中的线程，从M矩阵中读取数值，并放到tile_m中：此时sub = 1且 sub < 2(gridDim.x)

```
idx = row * n + sub * BLOCK_SIZE + threadIdx.x;
if(row<n && (sub * BLOCK_SIZE + threadIdx.x)<n )
{
    tile_a[threadIdx.y][threadIdx.x] = d_m[idx];
}
else{
    tile_a[threadIdx.y][threadIdx.x] = 0;
}
```

其中，最难理解的是这个idx：

idx = row * n + sub * BLOCK_SIZE + threadIdx.x;

我们以thread(3,4)为例，该线程的索引值：

threadIdx.x = 4
threadIdx.y = 3
blockIdx.x = 1
blockIdx.y = 1

此时，我们sub的迭代步骤为1，即sub=1

row * n:
该线程所在行之前所有行包含的数据

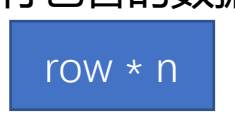

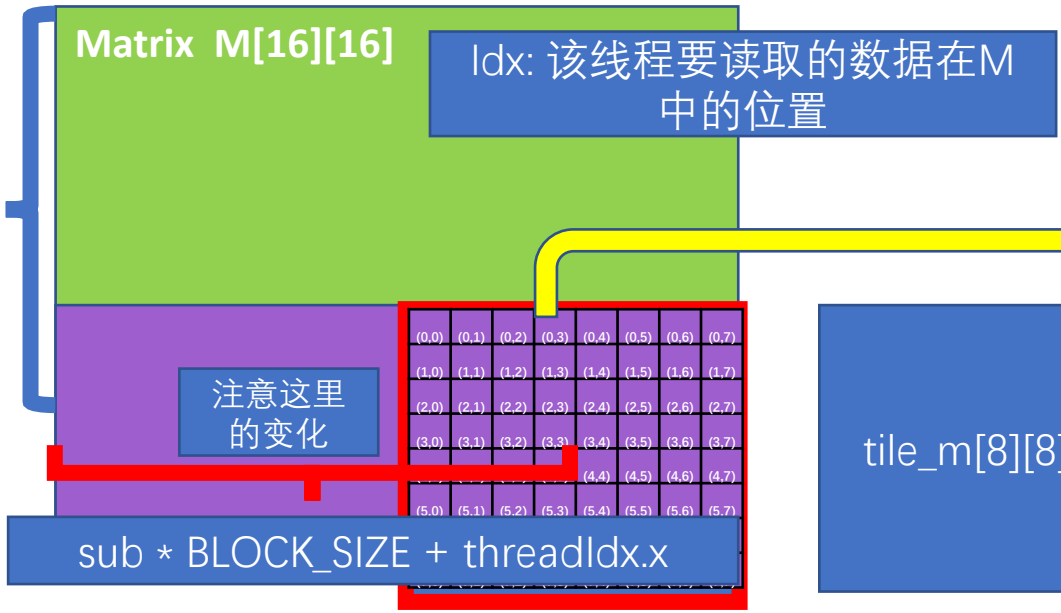

sub * BLOCK_SIZE + threadIdx.x:
该线程要读的数据在它所在的行中的位置

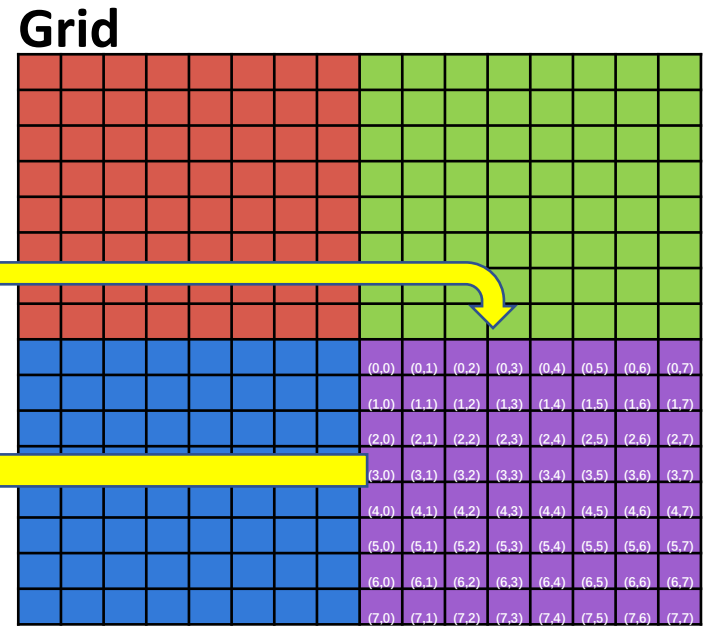

CUDA 矩阵乘示例：

接下来，Grid中紫色区域覆盖的block中的线程，从N矩阵中读取数值，并放到tile_n中：此时sub = 1且 sub < 2(gridDim.x)

```
idx = (sub * BLOCK_SIZE + threadIdx.y) * n + col;
if(col<n && (sub * BLOCK_SIZE + threadIdx.y)<n )
{
    tile_n[threadIdx.y][threadIdx.x] = d_n[idx];
}
else{
    tile_n[threadIdx.y][threadIdx.x] = 0;
}
```

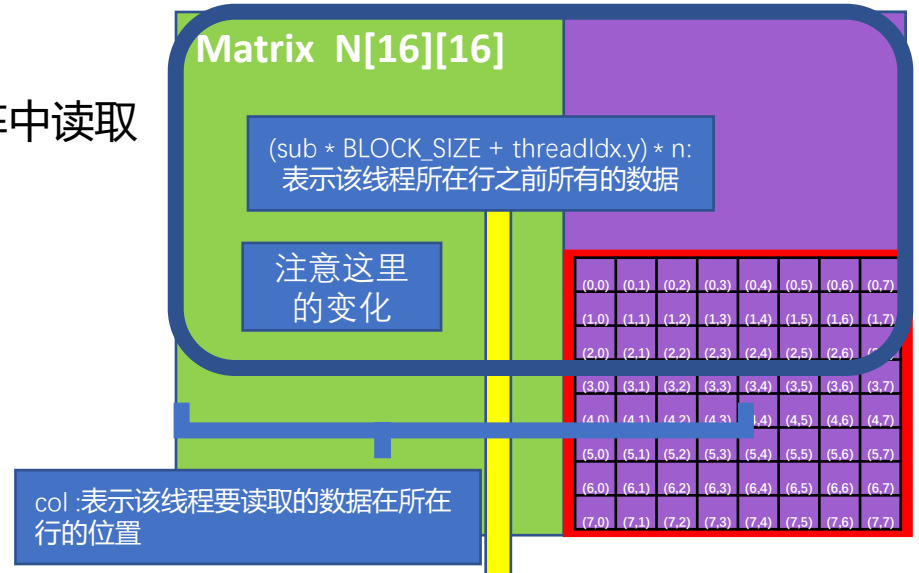

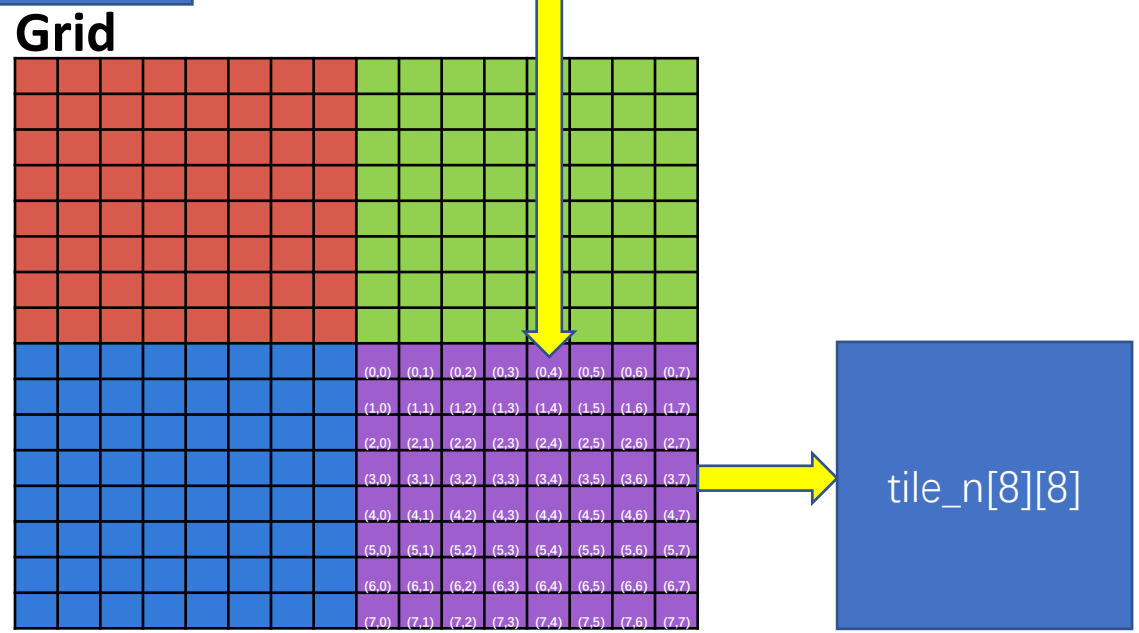

其中，最难理解的还是这个idx：

```
idx = (sub * BLOCK_SIZE + threadIdx.y) * n + col;
```

我们还是以thread(3,4)为例，该线程的索引值：

threadIdx.x = 4
threadIdx.y = 3
blockIdx.x = 1
blockIdx.y = 1

此时，我们sub的迭代步骤为1，即sub=1

CUDA 矩阵乘示例：

同步完所有的线程之后，我们紫色区域覆盖的线程块中的线程对已经读取到的两个tile中的矩阵进行相乘：

此时sub = 0且 sub < 2(gridDim.x)

```
__syncthreads();
for (int k = 0; k < BLOCK_SIZE; ++k)
{
    tmp += tile_m[threadIdx.y][k] * tile_n[k][threadIdx.x];
}
__syncthreads();
```

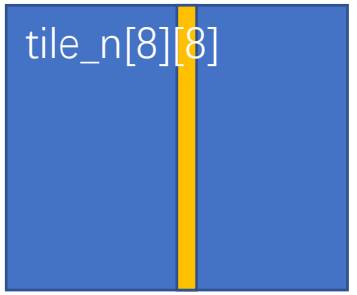

此时还以thread(3,4)为例：

它仍然会将tile_m中index为3的行与tile_n中index为4的列相乘，但是此时tile_m和tile_n中的数据已经发生变化

做完累加之后，将计算结果与上一个sub迭代步骤中的tmp相加

此时，thread(3,4)已经完成它的任务，迭代完所有的步骤。

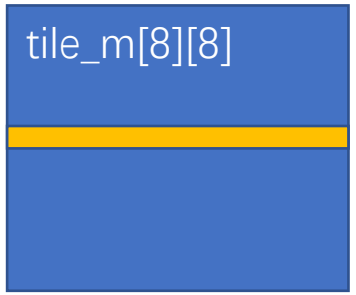

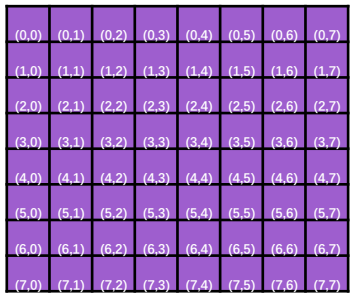

CUDA 矩阵乘示例：
当所有线程完成任务之后，每个线程将计算结果，写入结果矩阵P中对应的位置。

```
if(row < n && col < n)
    {
        d_result[row * n + col] = tmp;
    }
```

Matrix P

Grid

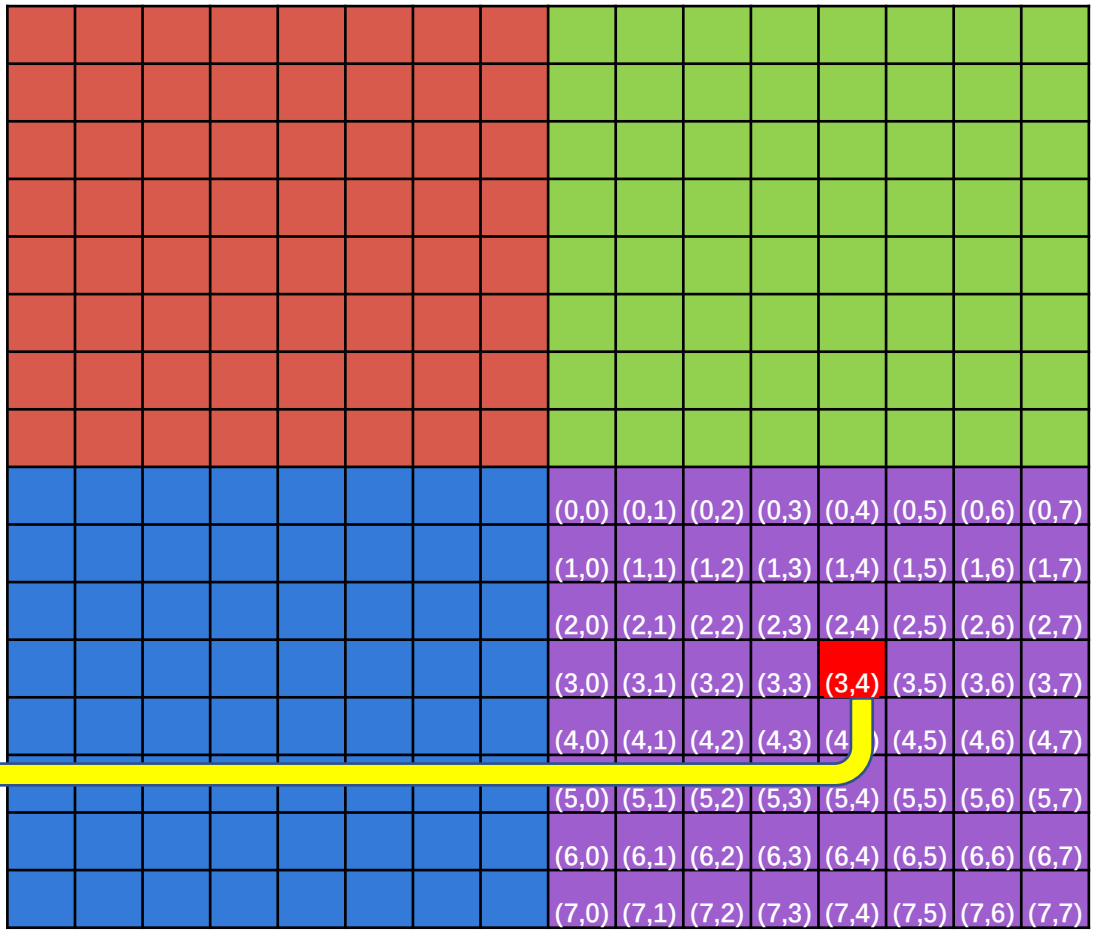

每次利用shared memory先读取一小块矩阵
每个线程
读入瓦片内 Md 和 Nd 的一个元素存入 shared memory

把 kernel 拆分成多个阶段
每个阶段用 Md 和 Nd 的子集累加Pd
每个阶段有很好的数据局部性

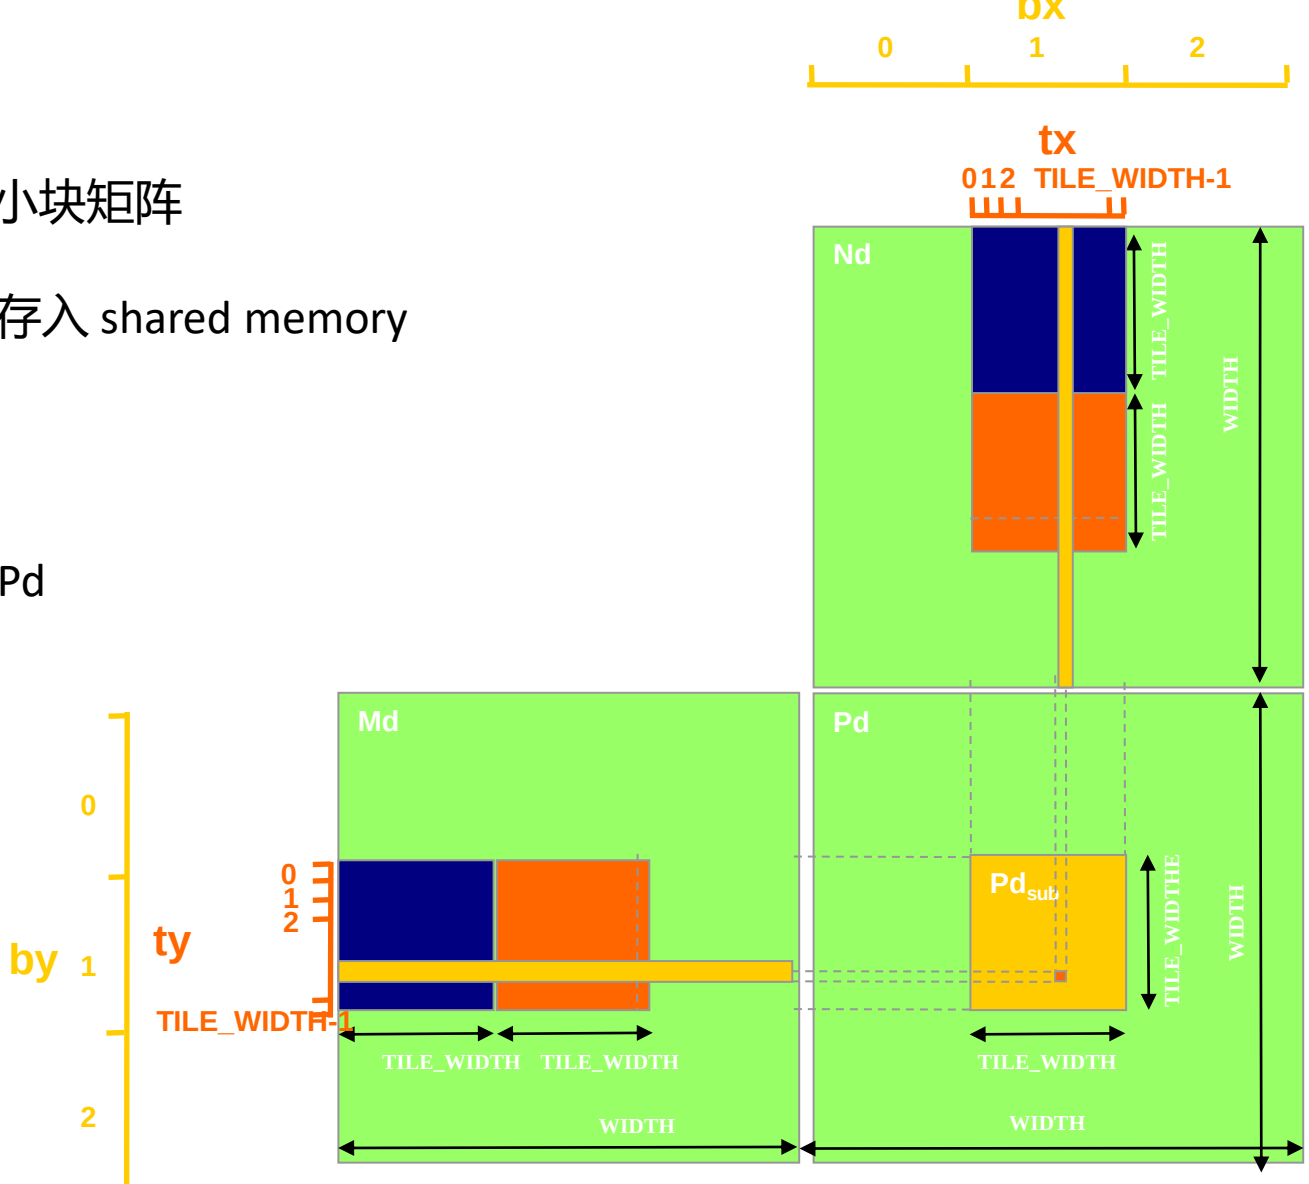

Image from http://courses.engr.illinois.edu/ece498/al/Syllabus.html

```
__global__ void MatrixMulKernel(
  float* Md, float* Nd, float* Pd, int Width)
{
  __shared__ float Mds[TILE_WIDTH][TILE_WIDTH];
  __shared__ float Nds[TILE_WIDTH][TILE_WIDTH];

  int bx = blockIdx.x;  int by = blockIdx.y;
  int tx = threadIdx.x; int ty = threadIdx.y;

  int Row = by * TILE_WIDTH + ty;
  int Col = bx * TILE_WIDTH + tx;

  float Pvalue = 0;
  for (int m = 0; m < Width/TILE_WIDTH; ++m) {
    Mds[ty][tx] = Md[Row*Width + (m*TILE_WIDTH + tx)];
    Nds[ty][tx] = Nd[Col + (m*TILE_WIDTH + ty)*Width];
    __syncthreads();

    for (int k = 0; k < TILE_WIDTH; ++k)
      Pvalue += Mds[ty][k] * Nds[k][tx];
    __synchthreads();
  }
  Pd[Row*Width+Col] = Pvalue;
}
```

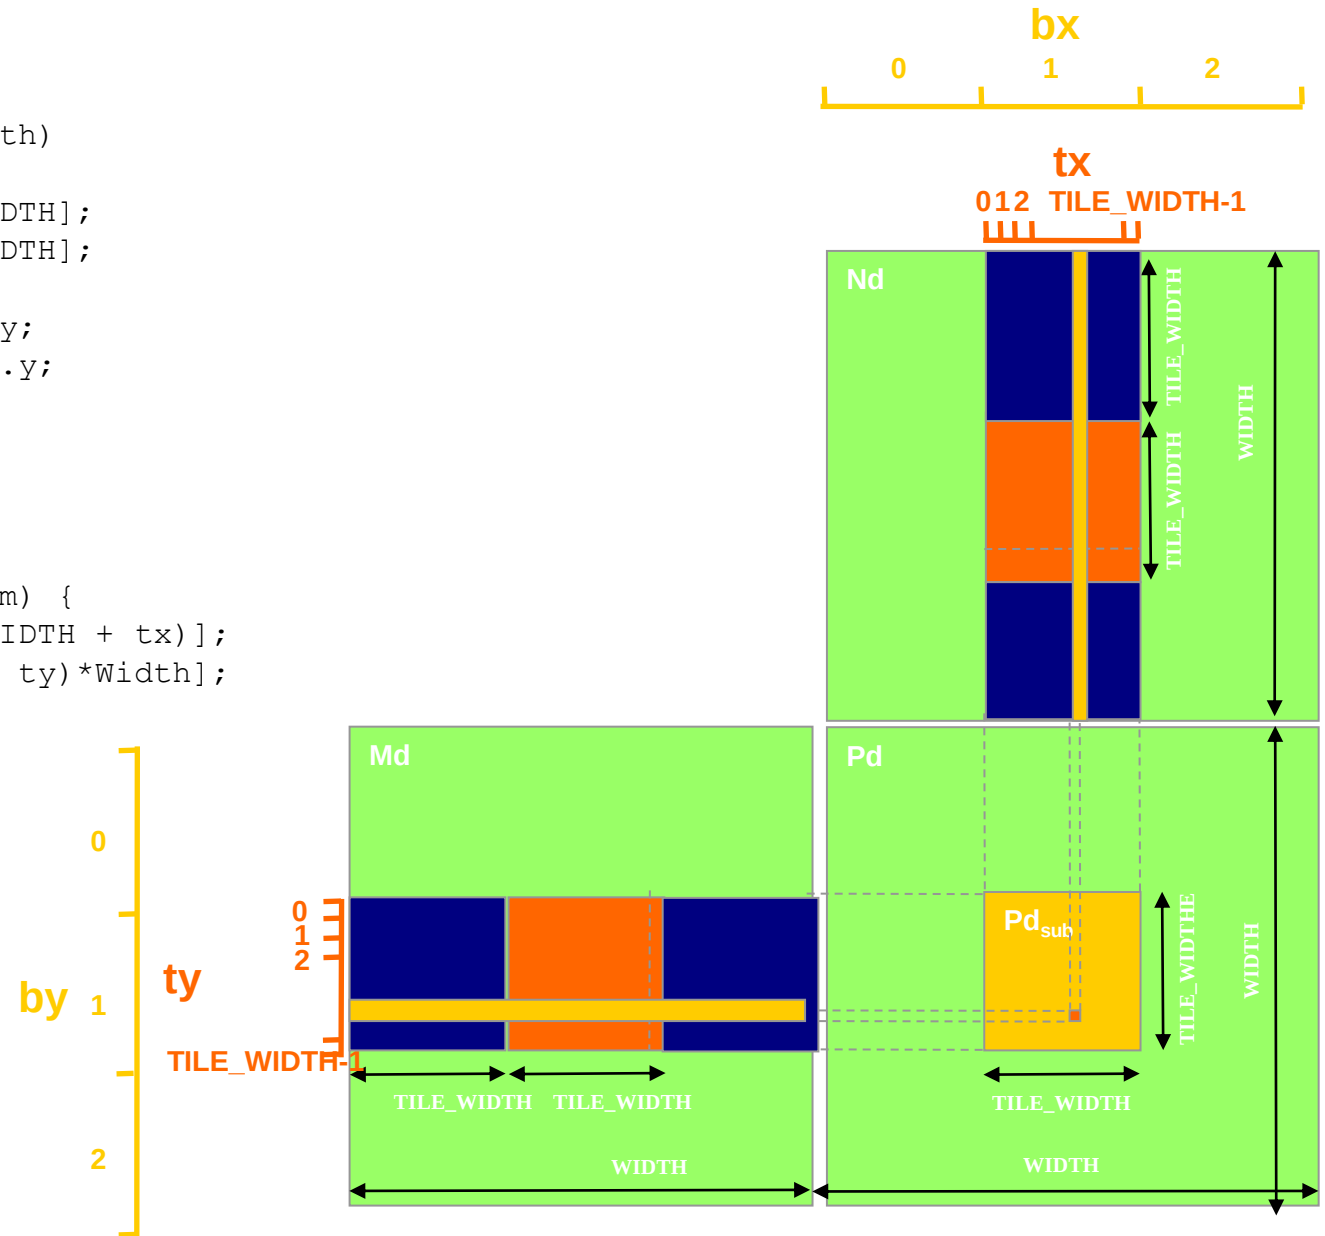

Shared memory 大小的选择

- 超出shared memory 极限
  P100: 48KB / SM 并且 8 blocks / SM
  - 6 KB / block
  - 3 KB 给 Nds， 3 KB 给 Mds (3 * 16 * 16 * 4)

所以我们设置多大的tile最合适?
如何更好地利用硬件?

Shared Memory优化

Global Memory:

空间最大，latency最高，GPU最基础的memory：

- 驻留在Device memory中
- memory transaction对齐，合并访存

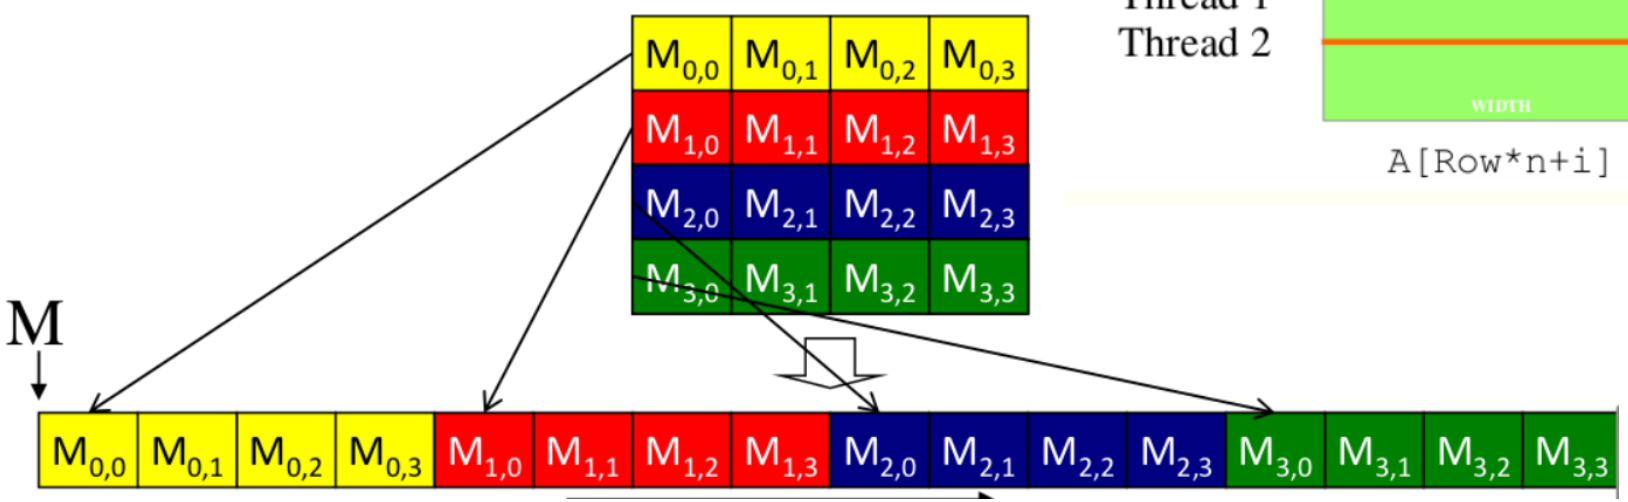

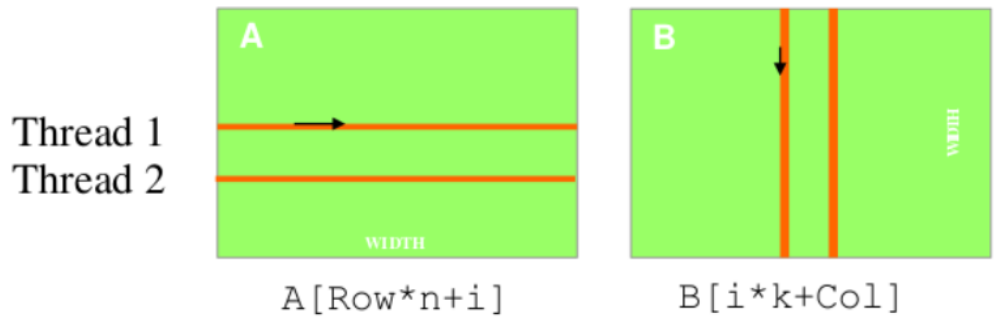

Shared Memory优化

Global Memory:

空间最大，latency最高，GPU最基础的memory：

- 驻留在Device memory中
- memory transaction对齐，合并访存

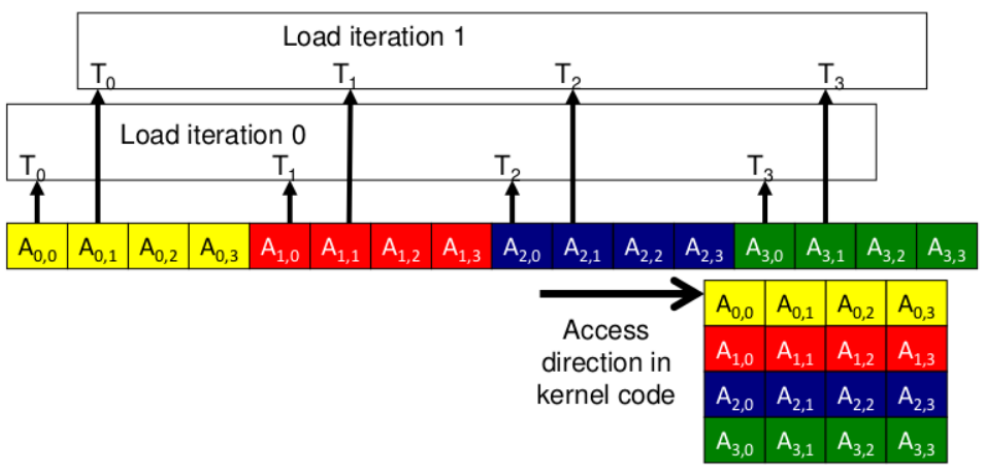

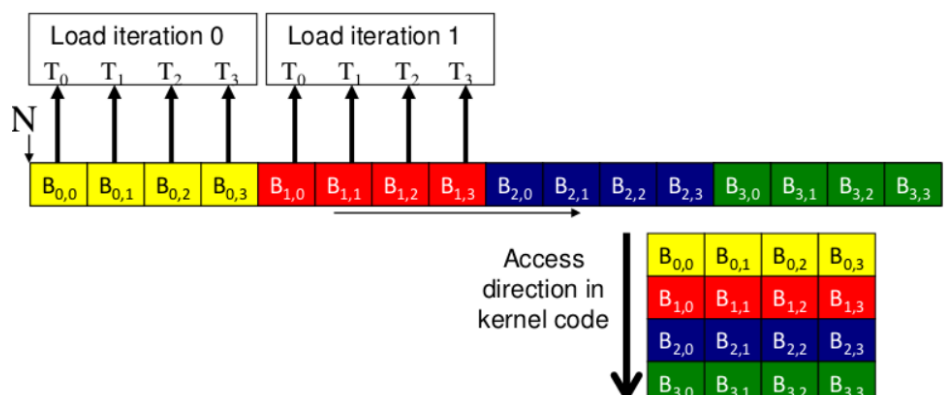

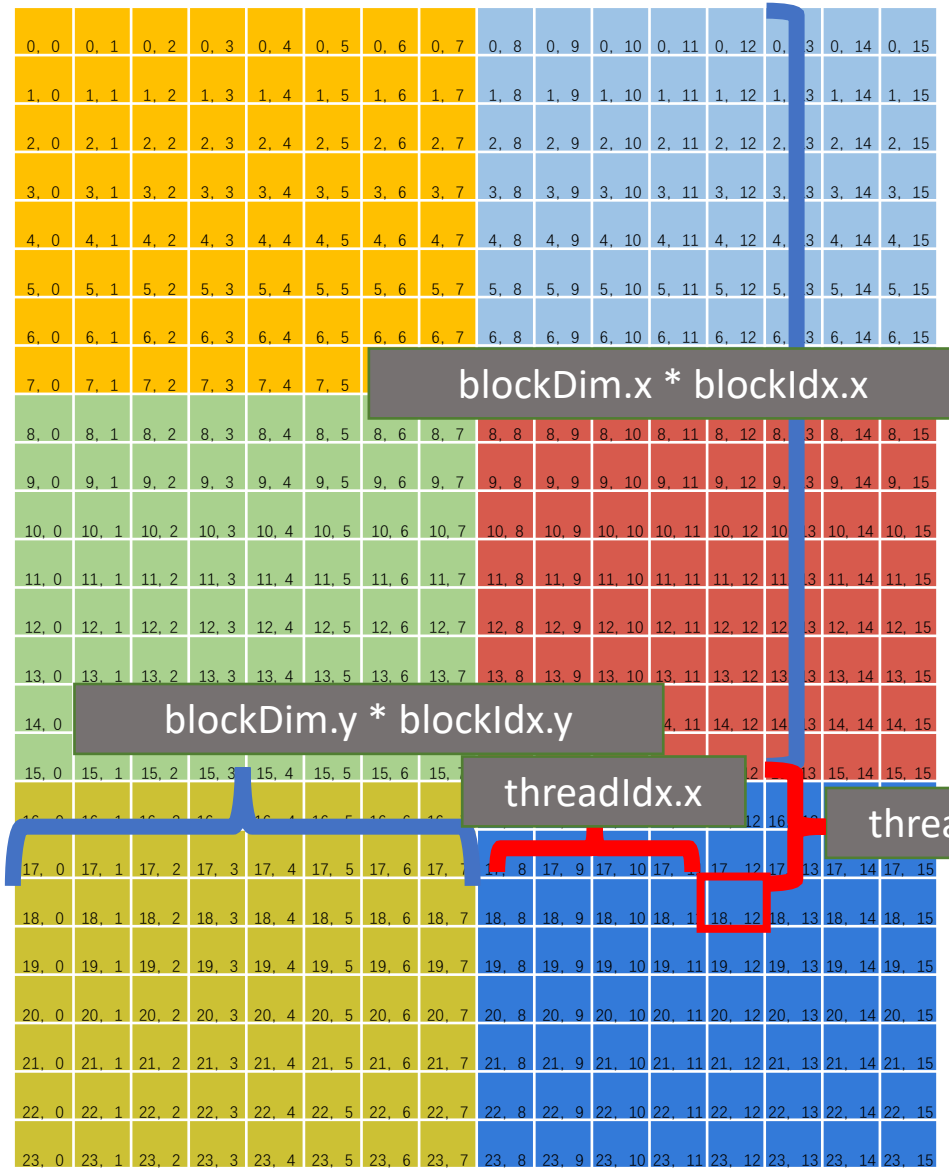

图二

```
int y = threadIdx.y + blockDim.y * blockIdx.y;
int x = threadIdx.x + blockDim.x * blockIdx.x;

__shared__ int ken[BLOCK_SIZE][BLOCK_SIZE+1];

if(x < M && y < N)
{
    ken[threadIdx.y][threadIdx.x] = in[y][x];
}
__syncthreads();

int x1 = threadIdx.x + blockDim.y * blockIdx.y;
int y1 = threadIdx.y + blockDim.x * blockIdx.x;
if(x1 < N && y1 < M)
{
    out[y1][x1] = ken[threadIdx.x][threadIdx.y];
}
```

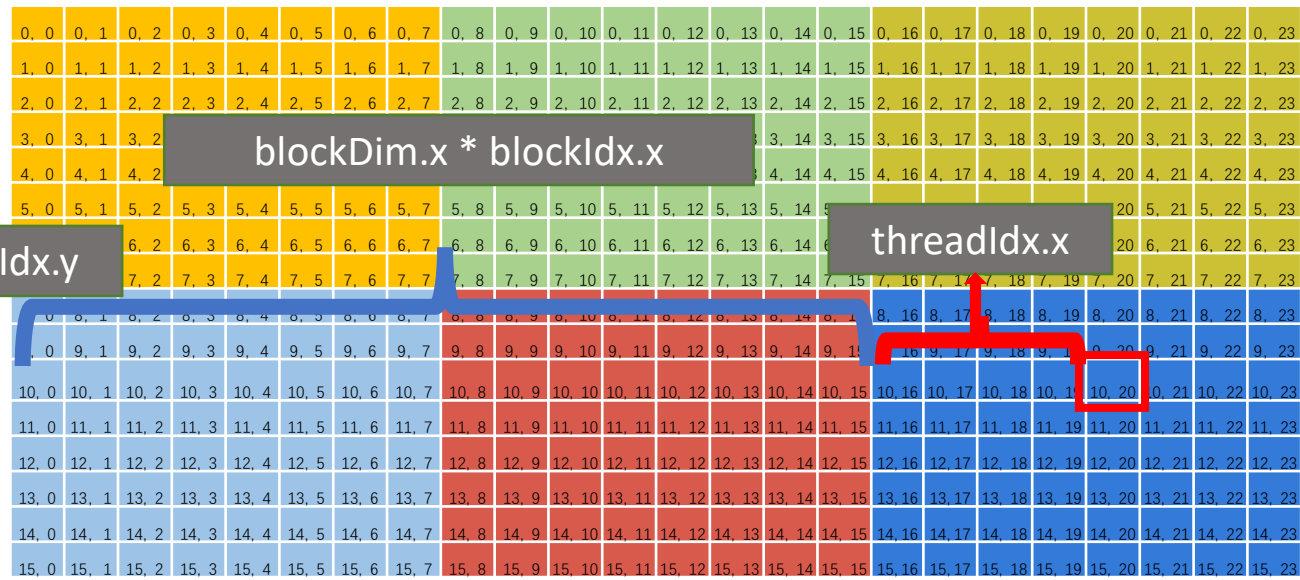

图一

更多资源:

https://developer.nvidia-china.com

何琨-Ken

北京 密云

扫一扫上面的二维码图案，加我微信

https://www.nvidia.cn/developer/community-training/


NVIDIA